基于用户的协同过滤来构建推荐系统

哥不是小萝莉 DataFunTalk 2020-09-22

文章作者：哥不是小萝莉，来源：
https://www.cnblogs.com/smartloli/

导读：协同过滤技术在推荐系统中应用的比较广泛，它是一个快速发展的研究领域。它比较常用的两种方法是基于内存（Memory-Based）和基于模型（Model-Based）。

- 基于内存：主要通过计算近似度来进行推荐，比如基于用户（Used-Based）和基于物品（Item-Based）的协同过滤，这两个模式中都会首先构建用户交互矩阵，然后矩阵的行向量和列向量可以用来表示用户和物品，然后计算用户和物品的相似度来进行推荐；

- 基于模型：主要是对交互矩阵进行填充，预测用户购买某个物品的可能性。

为了解决这些问题，可以通过建立协同过滤模型，利用购买数据向客户推荐产品。下面，我们通过基于用户的协同过滤（基于内存），通过实战来一步步实现其中的细节。基于用户的系统过滤体现在具有相似特征的人拥有相似的喜好。比如，用户A向用户B推荐了物品C，而B购买过很多类似C的物品，并且评价也高。那么，在未来，用户B也会有很大的可能会去购买物品C，并且用户B会基于相似度度量来推荐物品C。

01

基于用户与用户的协同过滤

这种方式识别与查询用户相似的用户，并估计期望的评分为这些相似用户评分的加权平均值。实战所使用的Python语言，这里需要依赖的库如下：

- pandas
- numpy
- sklearn

Python环境：

- 版本3.7.6
- Anaconda3

02

评分函数

这里给非个性化协同过滤（不包含活跃用户的喜欢、不喜欢、以及历史评分），返回一个以用户U和物品I作为输入参数的分数。该函数输出一个分数，用于量化用户U喜欢 / 偏爱物品I的程度。这通常是通过对与用户相似的人的评分来完成的。涉及的公式如下：

$$s(u,i) = \bar{r}_u + \frac{\sum_{v \in V}(r_{vi} - \bar{r}_v) * w_{uv}}{\sum_{v \in V} w_{uv}}$$

这里其中s为预测得分，u为用户，i为物品，r为用户给出的评分，w为权重。在这种情况下，我们的分数等于每个用户对该项目的评价减去该用户的平均评价再乘以某个权重的总和，这个权重表示该用户与其他用户有多少相似之处，或者对其他用户的预测有多少贡献。这是用户u和v之间的权重，分数在0到1之间，其中0是最低的，1是最高的。理论上看起来非常完美，那为啥需要从每个用户的评分中减去平均评分，为啥要使用加权平均而不是简单平均？这是因为我们所处理的用户类型，首先，人们通常在不同的尺度上打分，用户A可能是一个积极乐观的用户，会给用户A自己喜欢的电影平均高分（例如4分、或者5分）。而用户B是一个不乐观或者对评分标准比较高的用户，他可能对最喜欢的电影评分为2分到5分之间。用户B的2分对应到用户A的4分。改进之处是可以通过规范化用户评分来提高算法效率。一种方法是计算s(u,i)的分数，它是用户对每件物品的平均评价加上一些偏差。通过使用余弦相似度来计算上述公式中给出的权重，同时，按照上述方式对数据进行归一化，在pandas中进行一些数据分析。

1. 导入Python依赖包

```
import pandas as pd
import numpy as np
from sklearn.metrics.pairwise import cosine_similarity
from sklearn.metrics import pairwise_distances
```

2. 加载数据源

加载数据示例代码如下所示：

```
movies = pd.read_csv("data/movies.csv")
Ratings = pd.read_csv("data/ratings.csv")
Tags = pd.read_csv("data/tags.csv")
```

结果预览如下：

```
print(movies.head())
```

```
print(Ratings.head())
print(Tags.head())
```

```
   movieId                               title                                        genres
0        1                    Toy Story (1995)  Adventure|Animation|Children|Comedy|Fantasy
1        2                      Jumanji (1995)                 Adventure|Children|Fantasy
2        3             Grumpier Old Men (1995)                              Comedy|Romance
3        4            Waiting to Exhale (1995)                        Comedy|Drama|Romance
4        5  Father of the Bride Part II (1995)                                      Comedy
   userId  movieId  rating   timestamp
0   12882        1     4.0  1147195252
1   12882       32     3.5  1147195307
2   12882       47     5.0  1147195343
3   12882       50     5.0  1147185499
4   12882      110     4.5  1147195239
   movieId  userId          tag   timestamp
0     3916   12882       sports  1147195545
1     4085   12882  Eddie Murphy  1147195966
2    33660   12882       boxing  1147195514
3     1197     320    must show  1145964801
4     1396     320    must show  1145964810
```

构建数据：

```
Mean = Ratings.groupby(by="userId", as_index=False)['rating'].mean()
Rating_avg = pd.merge(Ratings, Mean, on='userId')
Rating_avg['adg_rating'] = Rating_avg['rating_x'] - Rating_avg['rating_y']
print(Rating_avg.head())
```

结果如下：

```
   userId  movieId  rating_x   timestamp  rating_y  adg_rating
0   12882        1       4.0  1147195252  4.061321   -0.061321
1   12882       32       3.5  1147195307  4.061321   -0.561321
2   12882       47       5.0  1147195343  4.061321    0.938679
3   12882       50       5.0  1147185499  4.061321    0.938679
4   12882      110       4.5  1147195239  4.061321    0.438679
```

03

余弦相似度

对于上面的公式，我们需要找到有相似想法的用户。找到一个喜欢和不喜欢的用户听起来很有意思，但是我们如何找到相似性呢？那么这里我们就需要用到余弦相似度，看看用户有多相似。它通常是根据用户过去的评分来计算的。

这里使用到Python的的sklearn的cosine_similarity函数来计算相似性，并做一些数据预处理和数据清洗。实例代码如下：

```
check = pd.pivot_table(Rating_avg,values='rating_x',index='userId',columns='mov
print(check.head())
final = pd.pivot_table(Rating_avg,values='adg_rating',index='userId',columns='m
print(final.head())
```

结果如下：

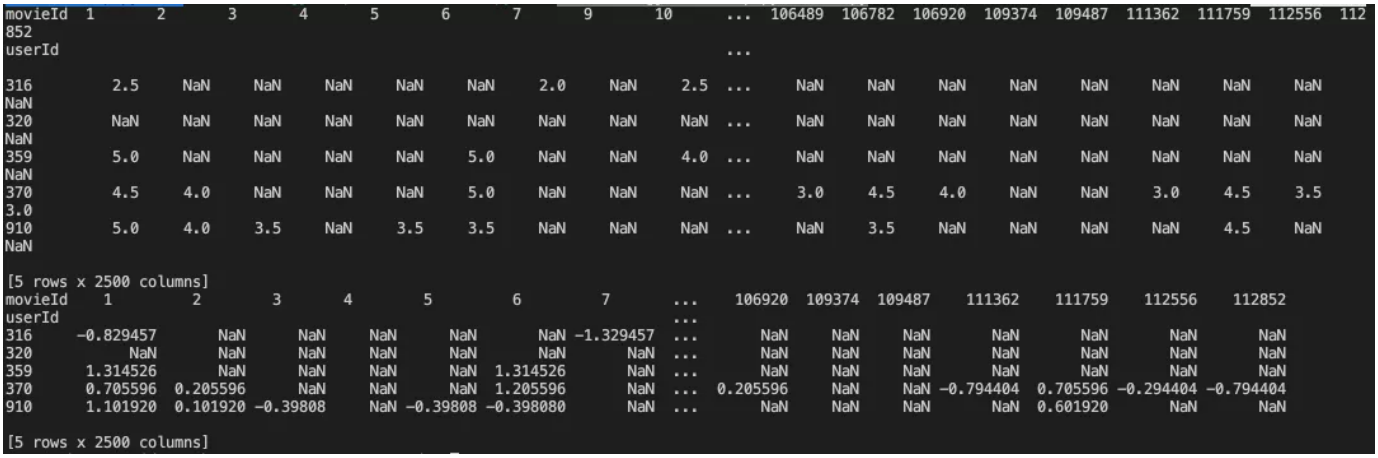

```
movieId  1       2      3      4      5      6      7      9      10     ...  106489  106782  106920  109374  109487  111362  111759  112556  112
852
userId                                                                   ...

316         2.5     NaN    NaN    NaN    NaN    NaN    2.0    NaN    2.5  ...     NaN     NaN     NaN     NaN     NaN     NaN     NaN     NaN
NaN
320         NaN     NaN    NaN    NaN    NaN    NaN    NaN    NaN    NaN  ...     NaN     NaN     NaN     NaN     NaN     NaN     NaN     NaN
NaN
359         5.0     NaN    NaN    NaN    NaN    5.0    NaN    NaN    4.0  ...     NaN     NaN     NaN     NaN     NaN     NaN     NaN     NaN
NaN
370         4.5     4.0    NaN    NaN    NaN    5.0    NaN    NaN    NaN  ...     3.0     4.5     4.0     NaN     NaN     3.0     4.5     3.5
3.0
910         5.0     4.0    3.5    NaN    3.5    3.5    NaN    NaN    NaN  ...     NaN     3.5     NaN     NaN     NaN     NaN     4.5     NaN
NaN

[5 rows x 2500 columns]
movieId    1         2         3         4         5         6         7       ...    106920    109374    109487    111362    111759    112556    112852
userId                                                                         ...
316     -0.829457       NaN       NaN       NaN       NaN       NaN -1.329457  ...       NaN       NaN       NaN       NaN       NaN       NaN       NaN
320           NaN       NaN       NaN       NaN       NaN       NaN       NaN  ...       NaN       NaN       NaN       NaN       NaN       NaN       NaN
359      1.314526       NaN       NaN       NaN       NaN  1.314526       NaN  ...       NaN       NaN       NaN       NaN       NaN       NaN       NaN
370      0.705596  0.205596       NaN       NaN       NaN  1.205596       NaN  ...  0.205596       NaN       NaN -0.794404  0.705596 -0.294404 -0.794404
910      1.101920  0.101920 -0.39808       NaN -0.39808 -0.398080       NaN  ...       NaN       NaN       NaN       NaN  0.601920       NaN       NaN

[5 rows x 2500 columns]
```

上图中包含了很多NaN的值，这是因为每个用户都没有看过所有的电影，所以这种类型的矩阵被称为稀疏矩阵。类似矩阵分解的方法被用来处理这种稀疏性，接下来，我们来对这些NaN值做相关替换。

这里通常有两种方式：

- 使用行上的用户平均值；
- 用户在列上的电影平均值

代码如下：

```
# Replacing NaN by Movie Average
final_movie = final.fillna(final.mean(axis=0))
print(final_movie.head())

```

```
# Replacing NaN by user Average
final_user = final.apply(lambda row: row.fillna(row.mean()), axis=1)
print(final_user.head())
```

结果如下：

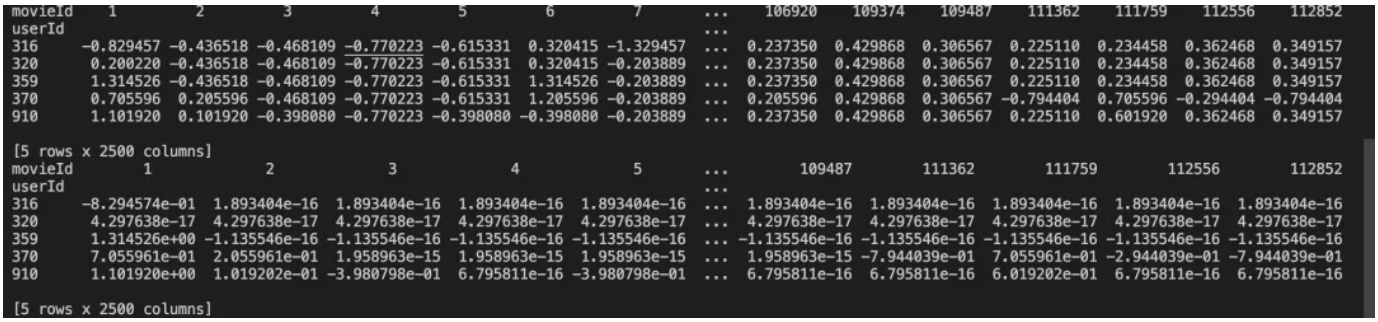

```
movieId    1         2         3         4         5         6         7       ...    106920    109374    109487    111362    111759    112556    112852
userId                                                                         ...
316     -0.829457 -0.436518 -0.468109 -0.770223 -0.615331  0.320415 -1.329457  ...  0.237350  0.429868  0.306567  0.225110  0.234458  0.362468  0.349157
320      0.200220 -0.436518 -0.468109 -0.770223 -0.615331  0.320415 -0.203889  ...  0.237350  0.429868  0.306567  0.225110  0.234458  0.362468  0.349157
359      1.314526 -0.436518 -0.468109 -0.770223 -0.615331  1.314526 -0.203889  ...  0.237350  0.429868  0.306567  0.225110  0.234458  0.362468  0.349157
370      0.705596  0.205596 -0.468109 -0.770223 -0.615331  1.205596 -0.203889  ...  0.205596  0.429868  0.306567 -0.794404  0.705596 -0.294404 -0.794404
910      1.101920  0.101920 -0.398080 -0.770223 -0.398080 -0.398080 -0.203889  ...  0.237350  0.429868  0.306567  0.225110  0.601920  0.362468  0.349157

[5 rows x 2500 columns]
movieId        1             2             3             4             5       ...        109487        111362        111759        112556        112852
userId                                                                         ...
316     -8.294574e-01  1.893404e-16  1.893404e-16  1.893404e-16  1.893404e-16  ...  1.893404e-16  1.893404e-16  1.893404e-16  1.893404e-16  1.893404e-16
320      4.297638e-17  4.297638e-17  4.297638e-17  4.297638e-17  4.297638e-17  ...  4.297638e-17  4.297638e-17  4.297638e-17  4.297638e-17  4.297638e-17
359      1.314526e+00 -1.135546e-16 -1.135546e-16 -1.135546e-16 -1.135546e-16  ... -1.135546e-16 -1.135546e-16 -1.135546e-16 -1.135546e-16 -1.135546e-16
370      7.055961e-01  2.055961e-01  1.958963e-15  1.958963e-15  1.958963e-15  ...  1.958963e-15 -7.944039e-01  7.055961e-01 -2.944039e-01 -7.944039e-01
910      1.101920e+00  1.019202e-01 -3.980798e-01  6.795811e-16 -3.980798e-01  ...  6.795811e-16  6.795811e-16  6.019202e-01  6.795811e-16  6.795811e-16

[5 rows x 2500 columns]
```

接着，我们开始计算用户之间的相似性，代码如下：

```
# user similarity on replacing NAN by item(movie) avg
cosine = cosine_similarity(final_movie)
np.fill_diagonal(cosine, 0)
similarity_with_movie = pd.DataFrame(cosine, index=final_movie.index)
similarity_with_movie.columns = final_user.index
# print(similarity_with_movie.head())

# user similarity on replacing NAN by user avg
b = cosine_similarity(final_user)
np.fill_diagonal(b, 0 )
similarity_with_user = pd.DataFrame(b,index=final_user.index)
similarity_with_user.columns=final_user.index
# print(similarity_with_user.head())
```

结果如下：

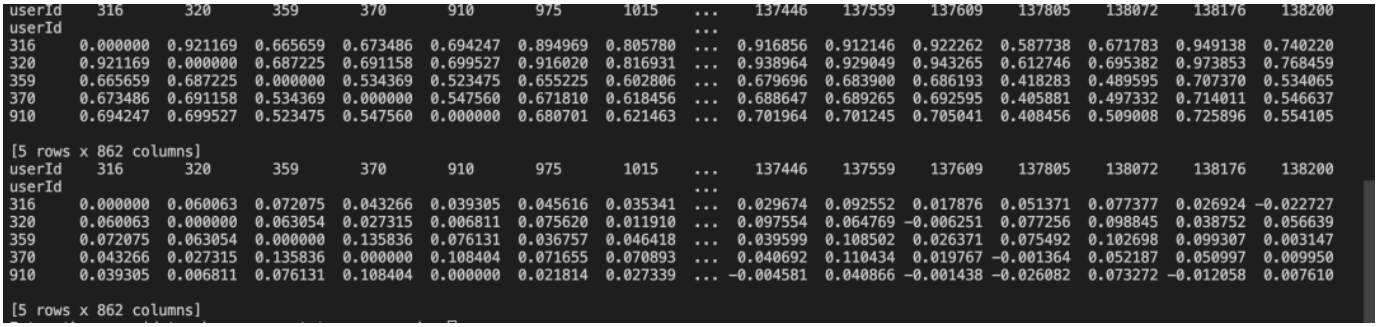

```
userId    316       320       359       370       910       975       1015   ...    137446    137559    137609    137805    138072    138176    138200
userId                                                                        ...
316      0.000000  0.921169  0.665659  0.673486  0.694247  0.894969  0.805780  ...  0.916856  0.912146  0.922262  0.587738  0.671783  0.949138  0.740220
320      0.921169  0.000000  0.687225  0.691158  0.699527  0.916020  0.816931  ...  0.938964  0.929049  0.943265  0.612746  0.695382  0.973853  0.768459
359      0.665659  0.687225  0.000000  0.534369  0.523475  0.655225  0.602806  ...  0.679696  0.683900  0.686193  0.418283  0.489595  0.707370  0.534065
370      0.673486  0.691158  0.534369  0.000000  0.547560  0.671810  0.618456  ...  0.688647  0.689265  0.692595  0.405881  0.497332  0.714011  0.546637
910      0.694247  0.699527  0.523475  0.547560  0.000000  0.680701  0.621463  ...  0.701964  0.701245  0.705041  0.408456  0.509008  0.725896  0.554105

[5 rows x 862 columns]
userId    316       320       359       370       910       975       1015   ...    137446    137559    137609    137805    138072    138176    138200
userId                                                                        ...
316      0.000000  0.060063  0.072075  0.043266  0.039305  0.045616  0.035341  ...  0.029674  0.092552  0.017876  0.051371  0.077377  0.026924 -0.022727
320      0.060063  0.000000  0.063054  0.027315  0.006811  0.075620  0.011910  ...  0.097554  0.064769 -0.006251  0.077256  0.098845  0.038752  0.056639
359      0.072075  0.063054  0.000000  0.135836  0.076131  0.036757  0.046418  ...  0.039599  0.108502  0.026371  0.075492  0.102698  0.099307  0.003147
370      0.043266  0.027315  0.135836  0.000000  0.108404  0.071655  0.070893  ...  0.040692  0.110434  0.019767 -0.001364  0.052187  0.050997  0.009950
910      0.039305  0.006811  0.076131  0.108404  0.000000  0.021814  0.027339  ... -0.004581  0.040866 -0.001438 -0.026082  0.073272 -0.012058  0.007610

[5 rows x 862 columns]
```

然后，我们来检验一下我们的相似度是否有效，代码如下：

```
def get_user_similar_movies( user1, user2 ):
    common_movies = Rating_avg[Rating_avg.userId == user1].merge(
    Rating_avg[Rating_avg.userId == user2],
    on = "movieId",
    how = "inner" )
    return common_movies.merge( movies, on = 'movieId' )

a = get_user_similar_movies(370,86309)
a = a.loc[ : , ['rating_x_x','rating_x_y','title']]
print(a.head())
```

结果如下：

```
   rating_x_x  rating_x_y                                              title
0         5.0         5.0                                  Matrix, The (1999)
1         5.0         4.5  Lord of the Rings: The Fellowship of the Ring,...
2         5.0         4.0      Lord of the Rings: The Two Towers, The (2002)
3         4.5         4.0  Lord of the Rings: The Return of the King, The...
4         1.5         1.0                                   Serenity (2005)
```

从上图中，我们可以看出产生的相似度几乎是相同的，符合真实性。

04

相邻用户

刚刚计算了所有用户的相似度，但是在大数据领域，推荐系统与大数据相结合是至关重要的。以电影推荐为例子，构建一个矩阵（862 * 862），这个与实际的用户数据（百万、千万或者更多）相比，这是

一个很小的矩阵。因此在计算任何物品的分数时，如果总是查看所有其他用户将不是一个好的解决方案或者方法。因此，采用相邻用户的思路，对于特定用户，只取K个类似用户的集合。

下面，我们对K取值30，所有的用户都有30个相邻用户，代码如下：

```
def find_n_neighbours(df,n):
    order = np.argsort(df.values, axis=1)[:, :n]
    df = df.apply(lambda x: pd.Series(x.sort_values(ascending=False)
           .iloc[:n].index,
          index=['top{}'.format(i) for i in range(1, n+1)]), axis=1)
    return df

# top 30 neighbours for each user
sim_user_30_u = find_n_neighbours(similarity_with_user,30)
print(sim_user_30_u.head())

sim_user_30_m = find_n_neighbours(similarity_with_movie,30)
print(sim_user_30_m.head())
```

结果如下：

```
        top1    top2    top3    top4    top5    top6    top7    top8    top9  ...   top22   top23   top24   top25   top26   top27   top28   top29   top30
userId                                                                        ...
316   113673  117918    9050   12882   38187  102668   98880   43829   13215  ...  120782   74472   53834   88928   42245   58265   89527   49830   63902
320    12288  113673   28159   79846  134627  112948  120729   97163    2945  ...   94883  127683  101137   54989  134521   80946   10055   64365  106512
359   102118   96482  102532   50898    2702   60016   23428  120782   57937  ...    7723  120729   61305   40768  117918   86768  129498  131620   58346
370    46645   42245   40768   23428  123707   60016   45120  113645   97195  ...   20530    2702   38159     359   43354  117144   96482    2988  108195
910    87042  131620   67352   40768   31321   48821   26222   63295    5611  ...   88738   46645  108195   70201   58265   18115  114601   23428   17039

[5 rows x 30 columns]
        top1    top2    top3    top4    top5    top6    top7    top8    top9  ...   top22   top23   top24   top25   top26   top27   top28   top29   top3
0
userId                                                                        ...
316   138176  100240   96936   51460   88932    1447  104732  125012    5268  ...   72633   21401  114335   22338  118304  124981   93203   81435   9433
3
320   138176   96936  121403    1447   51460  125012   88932   42944    5268  ...  102549  118304   86309   94333  124981   93203   80585  136037   2233
8
359   138176    1447    5268   96936  100240   21401   88932   13927  104732  ...  121987  114335  125012   51460  118304   57474   27142   80585   2233
8
370    86309   44194  138176   24802  129869   96936    1447  104529   94333  ...   27142  102549  120308   54643   42944   80585   13927   21401  13603
7
910    96936  107991  138176   27142   51460  125012   88932  100240   72633  ...   51255   94333   42944  121403   80585   61755  124981   88455   7890
8

[5 rows x 30 columns]
```

05

计算最后得分

实现代码如下所示：

```
def User_item_score(user,item):
    a = sim_user_30_m[sim_user_30_m.index==user].values
    b = a.squeeze().tolist()
    c = final_movie.loc[:,item]
    d = c[c.index.isin(b)]
    f = d[d.notnull()]
    avg_user = Mean.loc[Mean['userId'] == user,'rating'].values[0]
    index = f.index.values.squeeze().tolist()
    corr = similarity_with_movie.loc[user,index]
    fin = pd.concat([f, corr], axis=1)
    fin.columns = ['adg_score','correlation']
    fin['score']=fin.apply(lambda x:x['adg_score'] * x['correlation'],axis=1)
    nume = fin['score'].sum()
    deno = fin['correlation'].sum()
    final_score = avg_user + (nume/deno)
    return final_score

score = User_item_score(320,7371)
print("score (u,i) is",score)
```

结果如下：

```
score (u,i) is 4.255766437391595
```

这里我们算出来的预测分数是4.25，因此可以认为用户（370），可能喜欢ID（7371）的电影。接下来，我们给用户（370）做电影推荐，实现代码如下：

```
Rating_avg = Rating_avg.astype({"movieId": str})
Movie_user = Rating_avg.groupby(by = 'userId')['movieId'].apply(lambda x:','.

def User_item_score1(user):
    Movie_seen_by_user = check.columns[check[check.index==user].notna().any()]
    a = sim_user_30_m[sim_user_30_m.index==user].values
    b = a.squeeze().tolist()
    d = Movie_user[Movie_user.index.isin(b)]
    l = ','.join(d.values)
    Movie_seen_by_similar_users = l.split(',')
    Movies_under_consideration = list(set(Movie_seen_by_similar_users)-set(lis
```

```
    Movies_under_consideration = list(map(int, Movies_under_consideration))
    score = []
    for item in Movies_under_consideration:
        c = final_movie.loc[:,item]
        d = c[c.index.isin(b)]
        f = d[d.notnull()]
        avg_user = Mean.loc[Mean['userId'] == user,'rating'].values[0]
        index = f.index.values.squeeze().tolist()
        corr = similarity_with_movie.loc[user,index]
        fin = pd.concat([f, corr], axis=1)
        fin.columns = ['adg_score','correlation']
        fin['score']=fin.apply(lambda x:x['adg_score'] * x['correlation'],axis
        nume = fin['score'].sum()
        deno = fin['correlation'].sum()
        final_score = avg_user + (nume/deno)
        score.append(final_score)
    data = pd.DataFrame({'movieId':Movies_under_consideration,'score':score})
    top_5_recommendation = data.sort_values(by='score',ascending=False).head(5
    Movie_Name = top_5_recommendation.merge(movies, how='inner', on='movieId')
    Movie_Names = Movie_Name.title.values.tolist()
    return Movie_Names

user = int(input("Enter the user id to whom you want to recommend : "))
predicted_movies = User_item_score1(user)
print(" ")
print("The Recommendations for User Id : 370")
print("   ")
for i in predicted_movies:
    print(i)
```

结果如下：

```
Enter the user id to whom you want to recommend : 370

The Recommendations for User Id : 370

Band of Brothers (2001)
Godfather: Part II, The (1974)
Wallace & Gromit: The Wrong Trousers (1993)
Bicycle Thieves (a.k.a. The Bicycle Thief) (a.k.a. The Bicycle Thieves) (Ladri di biciclette) (1948)
Spirited Away (Sen to Chihiro no kamikakushi) (2001)
```

06

总结

基于用户的协同过滤，流程简述如下：

- 采集数据 & 存储数据
- 加载数据
- 数据建模（数据预处理 & 数据清洗）
- 计算相似性（余弦相似度、相邻计算）
- 得分预测（预测和最终得分计算）
- 物品推荐

今天的分享就到这里，谢谢大家。

在文末分享、点赞、在看，给个三连击呗~~

作者介绍：

哥不是小萝莉，知名博主，著有《 Kafka 并不难学 》和《 Hadoop 大数据挖掘从入门到进阶实战 》。

邮箱：smartloli.org@gmail.com

会员推荐：

DataFun会员计划重磅发布！多重权益加持，为你筑就数据科学家之路！扫码了解更多：