

推荐系统遇上深度学习(五)--Deep&Cross Network模型理论和实践

原创 文文 小小挖掘机 2018-04-22

收录于话题

#推荐系统遇上深度学习

95个

推荐系统遇上深度学习系列：

推荐系统遇上深度学习(一)--FM模型理论和实践

推荐系统遇上深度学习(二)--FFM模型理论和实践

推荐系统遇上深度学习(三)--DeepFM模型理论和实践

推荐系统遇上深度学习(四)--多值离散特征的embedding解决方案

1、原理

Deep&Cross Network模型我们下面将简称DCN模型：

一个DCN模型从嵌入和堆积层开始，接着是一个交叉网络和一个与之平行的深度网络，之后是最后的组合层，它结合了两个网络的输出。完整的网络模型如图：

$$x_{embed,i} = W_{embed,i} x_i$$

嵌入和堆叠层

我们考虑具有离散和连续特征的输入数据。在网络规模推荐系统中，如CTR预测，输入主要是分类特征，如“country=usa”。这些特征通常是编码为独热向量如“[0,1,0]”；然而，这往往导致过度的高维特征空间大的词汇。

为了减少维数，我们采用嵌入过程将这些离散特征转换成实数值的稠密向量（通常称为嵌入向量）：

$$x_{embed,i} = W_{embed,i} x_i$$

然后，我们将嵌入向量与连续特征向量叠加起来形成一个向量：

$$x_0 = [x_{embed,1}^T, \dots, x_{embed,n}^T, x_{cont,1}^T, \dots, x_{cont,m}^T]$$

拼接起来的向量X0将作为我们Cross Network和Deep Network的输入

Cross Network

交叉网络的核心思想是以有效的方式应用显式特征交叉。交叉网络由交叉层组成，每个层具有以下公式：

$$x_{l+1} = x_0 x_l^T w_l + b_l + x_l = f(x_l, w_l, b_l)$$

一个交叉层的可视化如图所示：




Figure 2: Visualization of a cross layer

可以看到，交叉网络的特殊结构使交叉特征的程度随着层深度的增加而增大。多项式的最高程度（就输入 x_0 而言）为 L 层交叉网络 $L + 1$ 。如果用 L_c 表示交叉层数， d 表示输入维度。然后，参数的数量参与跨网络参数为： $d * L_c * 2$ (w 和 b)

交叉网络的少数参数限制了模型容量。为了捕捉高度非线性的相互作用，模型并行地引入了一个深度网络。

Deep Network

深度网络就是一个全连接的前馈神经网络，每个深度层具有如下公式：

$$h_{l+1} = f(W_l h_l + b_l)$$

Combination Layer

链接层将两个并行网络的输出连接起来，经过一层全链接层得到输出：

$$p = \sigma \left([x_{L_1}^T, h_{L_2}^T] w_{\text{logits}} \right),$$

如果采用的是对数损失函数，那么损失函数形式如下：

$$\text{loss} = -\frac{1}{N} \sum_{i=1}^N y_i \log(p_i) + (1 - y_i) \log(1 - p_i) + \lambda \sum_l \|\mathbf{w}_l\|^2,$$

总结

DCN能够有效地捕获有限度的有效特征的相互作用，学会高度非线性的相互作用，不需要人工特征工程或遍历搜索，并具有较低的计算成本。

论文的主要贡献包括：

- 1) 提出了一种新的交叉网络，在每个层上明确地应用特征交叉，有效地学习有界度的预测交叉特征，并且不需要手工特征工程或穷举搜索。
- 2) 跨网络简单而有效。通过设计，各层的多项式级数最高，并由层深度决定。网络由所有的交叉项组成，它们的系数各不相同。
- 3) 跨网络内存高效，易于实现。
- 4) 实验结果表明，交叉网络（DCN）在LogLoss上与DNN相比少了近一个量级的参数量。

这个是从论文中翻译过来的，哈哈。

2、实现解析

本文的代码根据之前DeepFM的代码进行改进，我们只介绍模型的实现部分，其他数据处理的细节大家可以参考我的github上的代码：

https://github.com/princewen/tensorflow_practice/tree/master/Basic-DCN-Demo

数据下载地址：<https://www.kaggle.com/c/porto-seguro-safe-driver-prediction>

不去下载也没关系，我在github上保留了几千行的数据用作模型测试。

模型输入

模型的输入主要有下面几个部分：

```
self.feats_index = tf.placeholder(tf.int32,
                                shape=[None, None],
                                name='feats_index')
self.feats_value = tf.placeholder(tf.float32,
                                shape=[None, None],
                                name='feats_value')

self.numeric_value = tf.placeholder(tf.float32, [None, None], name='num_value')

self.label = tf.placeholder(tf.float32, shape=[None, 1], name='label')
self.dropout_keep_deep = tf.placeholder(tf.float32, shape=[None], name='dropout_deep')
```

可以看到，这里与DeepFM相比，一个明显的变化是将离散特征和连续特征分开，连续特征不再转换成embedding进行输入，所以我们的输入共有五部分。

feat_index是离散特征的一个序号，主要用于通过embedding_lookup选择我们的embedding。feat_value是对应离散特征的特征值。numeric_value是我们的连续特征值。label是实际值。还定义了dropout来防止过拟合。

权重构建

权重主要包含四部分，embedding层的权重，cross network中的权重，deep network中的权重以及最后链接层的权重，我们使用一个字典来表示：

```
def _initialize_weights(self):
    weights = dict()

    #embeddings
    weights['feature_embeddings'] = tf.Variable(
        tf.random_normal([self.cate_feature_size,self.embedding_size],0.0,0.01),
        name='feature_embeddings')
    weights['feature_bias'] = tf.Variable(tf.random_normal([self.cate_feature_size,1],0.0,1.0),name='feature_bias')

    #deep layers
    num_layer = len(self.deep_layers)
    glorot = np.sqrt(2.0/(self.total_size + self.deep_layers[0]))

    weights['deep_layer_0'] = tf.Variable(
        np.random.normal(loc=0,scale=glorot,size=(self.total_size,self.deep_layers[0])),
        dtype=np.float32
    )
    weights['deep_bias_0'] = tf.Variable(
        np.random.normal(loc=0,scale=glorot,size=(1,self.deep_layers[0])),dtype=np.float
    32
    )

    for i in range(1,num_layer):
        glorot = np.sqrt(2.0 / (self.deep_layers[i - 1] + self.deep_layers[i]))
        weights["deep_layer_%d" % i] = tf.Variable(
            np.random.normal(loc=0, scale=glorot, size=(self.deep_layers[i - 1], self.de
            ep_layers[i])),
            dtype=np.float32) # layers[i-1] * layers[i]
        weights["deep_bias_%d" % i] = tf.Variable(
            np.random.normal(loc=0, scale=glorot, size=(1, self.deep_layers[i])),
            dtype=np.float32) # 1 * layer[i]

    for i in range(self.cross_layer_num):

        weights["cross_layer_%d" % i] = tf.Variable(
            np.random.normal(loc=0, scale=glorot, size=(self.total_size,1)),
            dtype=np.float32)
        weights["cross_bias_%d" % i] = tf.Variable(
            np.random.normal(loc=0, scale=glorot, size=(self.total_size,1)),
            dtype=np.float32) # 1 * Layer[i]

    # final concat projection layer
```

```

input_size = self.total_size + self.deep_layers[-1]

glorot = np.sqrt(2.0/(input_size + 1))
weights['concat_projection'] = tf.Variable(np.random.normal(loc=0, scale=glorot, size=
(input_size,1)), dtype=np.float32)
weights['concat_bias'] = tf.Variable(tf.constant(0.01), dtype=np.float32)

return weights

```

计算网络输入

这一块我们要计算两个并行网络的输入 X_0 ，我们需要将离散特征转换成embedding，同时拼接上连续特征：

```

# model
self.embeddings = tf.nn.embedding_lookup(self.weights['feature_embeddings'], self.fea
t_index) # N * F * K
feat_value = tf.reshape(self.feats_value, shape=[-1, self.field_size, 1])
self.embeddings = tf.multiply(self.embeddings, feat_value)

self.x0 = tf.concat([self.numeric_value,
                    tf.reshape(self.embeddings, shape=[-1, self.field_size * self.emb
edding_size])],
                    , axis=1)

```

Cross Network

根据论文中的计算公式，一步步计算得到cross network的输出：

```

# cross_part
self._x0 = tf.reshape(self.x0, (-1, self.total_size, 1))
x_1 = self._x0
for l in range(self.cross_layer_num):
    x_1 = tf.tensordot(tf.matmul(self._x0, x_1, transpose_b=True),
                      self.weights["cross_layer_%d" % l], 1) + self.weights["cross_
bias_%d" % l] + x_1

self.cross_network_out = tf.reshape(x_1, (-1, self.total_size))

```

Deep Network

这一块就是一个多层全链接神经网络：

```

self.y_deep = tf.nn.dropout(self.x0, self.dropout_keep_deep[0])

for i in range(0, len(self.deep_layers)):
    self.y_deep = tf.add(tf.matmul(self.y_deep, self.weights["deep_layer_%d" % i]), se
lf.weights["deep_bias_%d" % i])
    self.y_deep = self.deep_layers_activation(self.y_deep)
    self.y_deep = tf.nn.dropout(self.y_deep, self.dropout_keep_deep[i+1])

```

Combination Layer

最后将两个网络的输出拼接起来，经过一层全链接得到最终的输出：

```
# concat_part
concat_input = tf.concat([self.cross_network_out, self.y_deep], axis=1)

self.out = tf.add(tf.matmul(concat_input, self.weights['concat_projection']), self.weights['concat_bias'])
```

定义损失

这里我们可以选择logloss或者mse，并加上L2正则项：

```
# loss
if self.loss_type == "logloss":
    self.out = tf.nn.sigmoid(self.out)
    self.loss = tf.losses.log_loss(self.label, self.out)
elif self.loss_type == "mse":
    self.loss = tf.nn.l2_loss(tf.subtract(self.label, self.out))
# l2 regularization on weights
if self.l2_reg > 0:
    self.loss += tf.contrib.layers.l2_regularizer(
        self.l2_reg)(self.weights["concat_projection"])
    for i in range(len(self.deep_layers)):
        self.loss += tf.contrib.layers.l2_regularizer(
            self.l2_reg)(self.weights["deep_layer_%d" % i])
    for i in range(self.cross_layer_num):
        self.loss += tf.contrib.layers.l2_regularizer(
            self.l2_reg)(self.weights["cross_layer_%d" % i])
```

剩下的代码就不介绍啦！

好啦，本文只是提供一个引子，有关DCN的知识大家可以更多的进行学习呦。

参考文章：

- 1、<https://blog.csdn.net/roguesir/article/details/79763204>
- 2、论文：<https://arxiv.org/abs/1708.05123>

推荐阅读：强化学习系列

实战深度强化学习DQN-理论和实践

DQN三大改进(一)-Double DQN

DQN三大改进(二)-Prioritised replay

DQN三大改进(三)-Dueling Network