知乎

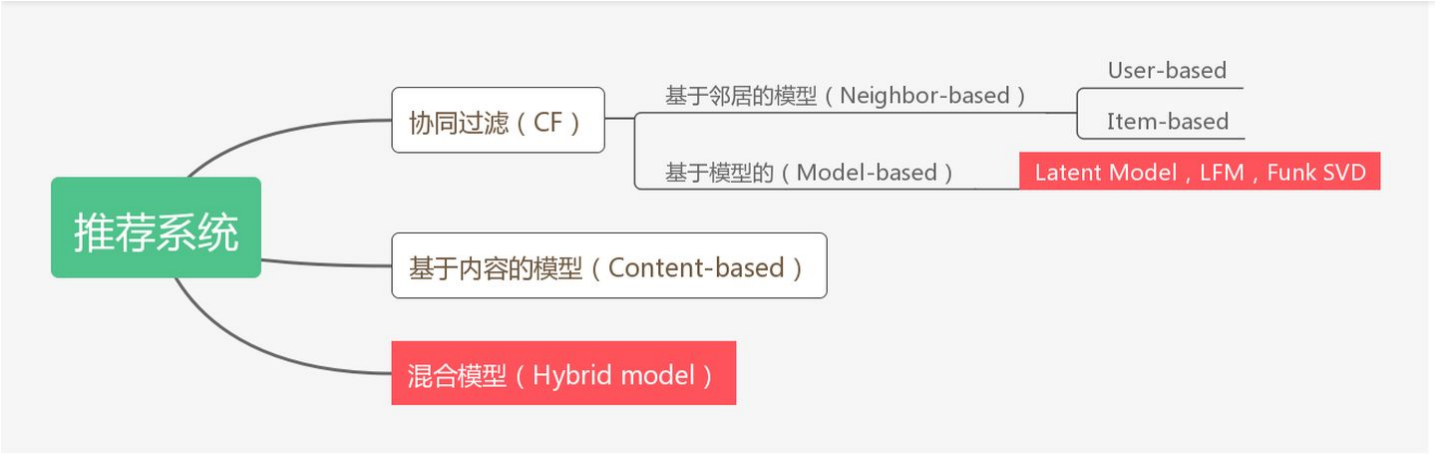

使用Dropout解决推荐系统冷启动问题

蝈蝈
把知道的讲清楚。公众号SimpleAI，欢迎来逛逛。
关注他

推荐系统回顾 & 冷启动问题

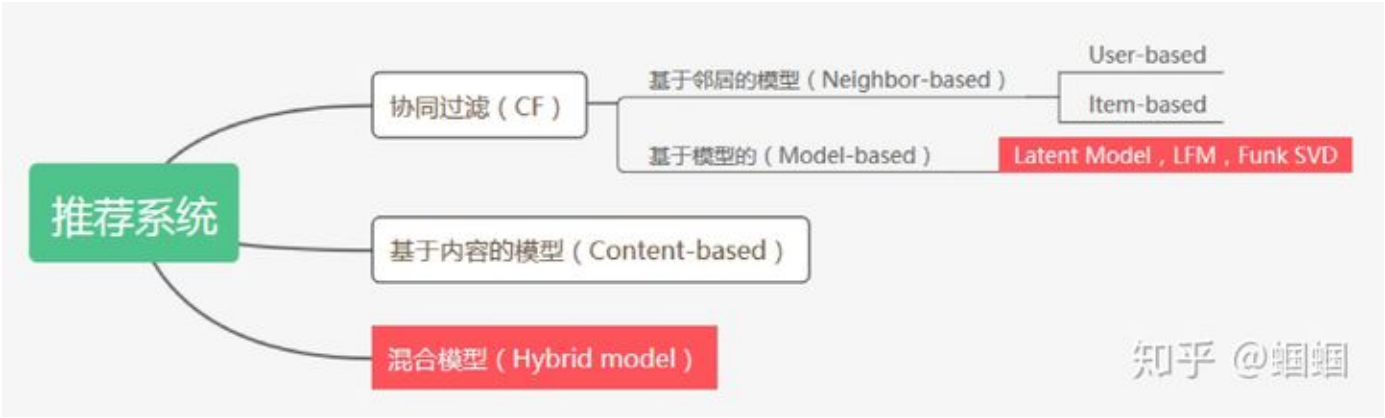

推荐系统的协同过滤算法分为两类：**基于记忆的**（Memory-based，具体包括User-based和Item-based），**基于模型的**（Model-based）和**基于内容的**（Content-based）。在基于模型的方法中，**隐模型（Latent Model）**又是其中的代表，并且已经成为大多数推荐系统的选择，例如基于矩阵分解的LFM（Latent Factor Model）。

LFM主要依靠Users和Items形成的**偏好矩阵（Preference Matrix）**来估计出一个可以补全原偏好矩阵的两个分解矩阵。这种方法简单有效，而且因为分解出来的矩阵大小远远小于原矩阵，所以也十分节省存储空间。

但是，以LFM为代表的利用Users和Items的交互信息来进行推荐的隐模型，**矩阵越稀疏，效果就会越差，极端情况就是，来了一些新的User或者Item，它们压根没有任何历史交互信息，即冷启**

验中被发现，性能远远不如Memory-based的方法。

本文介绍的一篇论文，提出了一种借用神经网络中的**Dropout**的思想，来处理冷启动问题，想法十分新颖而有趣。而且，本文提出的一种模型，可以结合Memory和Content的信息，但是只使用一个目标函数，即拥有了以往Hybrid model的性能，还解决了冷启动问题，同时大大降低了模型训练的复杂程度。

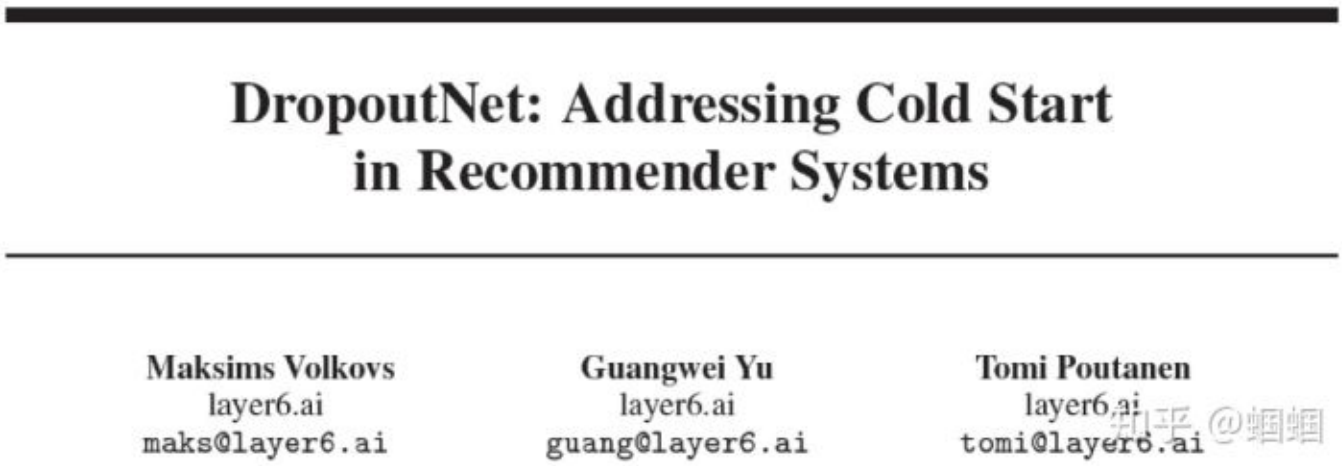

DropoutNet: Addressing Cold Start in Recommender Systems

Maksims Volkovs
layer6.ai
maks@layer6.ai

Guangwei Yu
layer6.ai
guang@layer6.ai

Tomi Poutanen
layer6.ai
tomi@layer6.ai

Ⅰ. 论文主要思想

前面讲了，要处理冷启动问题，我们必须使用content信息。但是想要整个系统的推荐效果较好，我们也必须使用preference信息。目前最好的方法，就是二者结合形成的Hybrid方法，但是往往有多目标函数，训练复杂。于是本文的作者就想：

> **如何把content和preference的信息都结合起来，同时让训练过程更简单呢?**

作者们想到，冷启动问题，就**相当于一种数据缺失**问题。而数据缺失的问题又**可以使用Dropout来进行模拟。**

因此，针对冷启动问题，本文不是引入额外的内容信息和额外的目标函数，而是改进整个学习过程，让模型可以针对这种缺失的输入来训练。

Ⅱ. Notations

我们先定义一些notations：

$\mathcal{U}$ 和 $\mathcal{V}$ 形成的 $M \times N$ 的preference矩阵为 R ，而 R_{uv} 代表的是用户u对项目v的preference，即R的第u行第v列。

对于一个新的User或者Item，就有 $R_{uv} = 0$ 。

这些都是**preference**的信息。接下来定义**content**信息：

说了半天content，到底是啥？对于user来说，content可以是user的个人资料，如性别年龄个人评价等等，也可以是其社交网络的信息，对于item，content可以是一个商品的基本信息，如产地、类型、品牌、评论等等，也可以是相关的视频图片资料。总之，content可以是通过各种渠道获取的额外信息，信息越多，当然对推荐的贡献也会越大。

来自各种渠道的多种类的信息，为了便于处理，我们统一表示成定长的向量，具体方法多种多样，比如通过一个DNN来形成，或者使用训练好的词向量等等。

我们定义: user和item得到的content feature分别为 $\Phi^{\mathcal{U}}$ 和 $\Phi^{\mathcal{V}}$ ， 则 $\Phi^{\mathcal{U}}u(\Phi^{\mathcal{V}}v)$ 就代表用户u（项目v）的content向量。

我们的目标就是使用 $\mathbf{R}, \Phi^{\mathcal{U}}$ 和 $\Phi^{\mathcal{V}}$ 来训练一个准确又鲁棒的模型。

Ⅲ. 模型框架 & 训练方法

前面讲过，我们是使用R,$\Phi^{\mathcal{U}}$和$\Phi^{\mathcal{V}}$来训练模型，R如何输入呢？直接的想法就是把R的每一行每一列作为Users和Items的preference向量输入，但是由于Users和Items数量太大了，难以训练。这个时候，之前的LFM就派上用场了。我们先把R分解成两个小矩阵U和V，我们可以认为，U和V相乘可以基本重构R，涵盖了R的绝大部分信息。所以，在preference方面，我们使用U和V来代替R作为模型的输入。

即

$$R \approx UV^T, R_{uv} \approx U_u V_v^T$$

我们对于用户u，输入是 $[U_u, \Phi^{\mathcal{U}}u]$ ；*对于项目v，输入是* $[Vv, \Phi^{\mathcal{V}}v]$ ，*然后分别输入一个深度神经网络中，得到用户u和项目v各自的一个新的向量* $\hat{U}u$ 和 $\hat{V}_v$ 。

用新得到的u和v的向量 $\hat{U}u$ *和* $\hat{V}v$ ，我们可以接着相乘得到一个R的新的估计 $\hat{U}u\hat{V}v^T$.

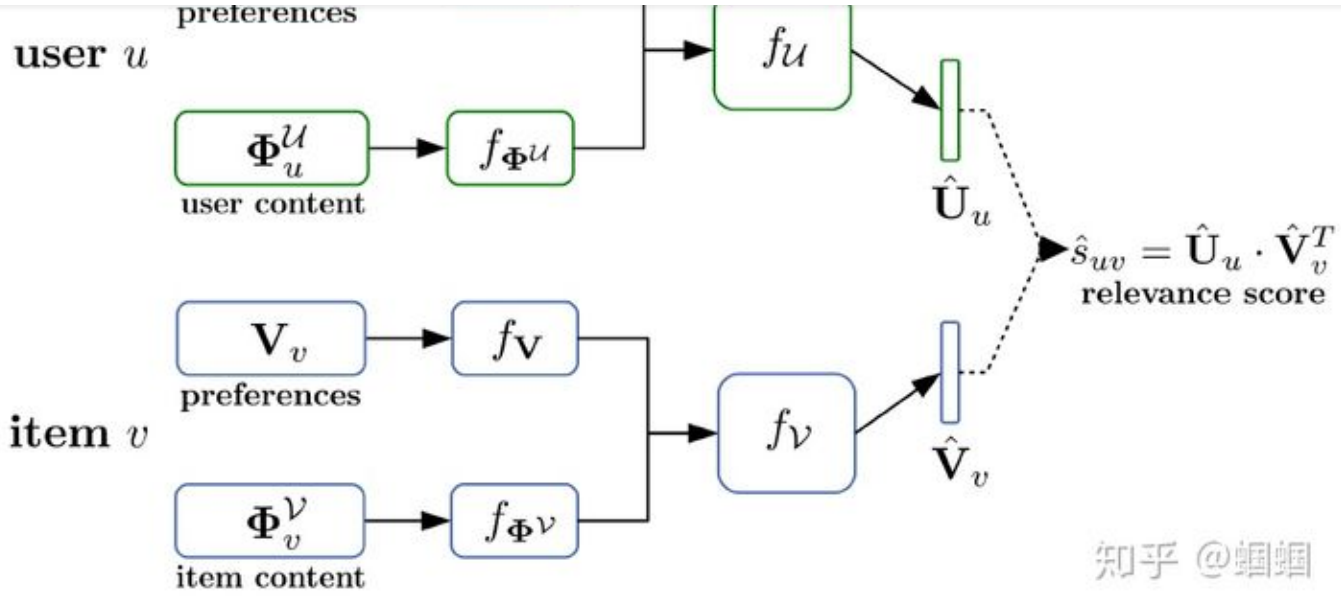

定义我们的目标函数为：

$$\mathcal{O} = \sum_{u,v}(U_u V_v^T - \hat{U}u\hat{V}v^T)^2 = \sum_{u,v}(U_u V_v^T - f\mathcal{U}(U_u, \Phi^{\mathcal{U}u}) f\mathcal{V}(V_v, \Phi^{\mathcal{V}_v})^T)^2.$$

这个目标函数一开始不大理解，直接从公式看，就是希望我们训练出来的两个user和item的向量尽可能拟合原来的向量。$U_{u} V_{v}^{T}$可以看做是通过Latent Model得到的，而$\hat{U}{u} \hat{V}{v}^{T}$可以看做是通过一个深度神经网络DNN得到的。所以目标函数就是缩小Latent Model与DNN的差异。而Latent Model的结果是固定的，DNN是依靠我们训练的，所以是以Latent Model为标杆来训练的。

后来读完全篇之后，才明白，在训练的时候，我们选择的 U_u 和 V_v 都是有比较丰富的preference信息的向量，**在实际推荐中，如果preference信息比较丰富，那么我们只利用这些信息就可以得到很好的推荐效果。**我们在冷启动时利用content信息，也是希望能够达到有preference信息时候的性能。所以，当我们有充足的preference信息的时候，训练出的模型给予ntent内容的权重会趋于0，这样就回归了传统的Latent Model了。

在训练时，为了**模拟冷启动**问题，我们会按照一定的抽样比例，**让user或者item的preference向量为0**，即 U_u 或者 V_v 为 0 。所以，针对冷启动，其目标函数为：

$$\textbf{User } cold\ start: \quad \mathcal{O}uv = \left(\mathbf{U}u\mathbf{V}v^T - f\mathcal{U}\left(\mathbf{0}, \mathbf{\Phi}u^u\right) f\mathcal{V}\left(\mathbf{V}v, \mathbf{\Phi}v^{\mathcal{V}}\right)\right)^2$$

$$\textbf{Item } cold\ start: \quad \mathcal{O}uv = \left(\mathbf{U}u\mathbf{V}v^T - f\mathcal{U}\left(\mathbf{U}u, \mathbf{\Phi}u^u\right) f_{\mathcal{V}}\left(\mathbf{0}, \mathbf{\Phi}_v^{\mathcal{V}}\right)\right)^2 \$$

知乎

从上面的分析可以看出，**仅仅使用一个目标函数，这个模型就可以一箭双雕**：设置dropout的时候，鼓励模型去使用content信息；不设置dropout的时候，模型会尽量使用preference信息。另外，本身Dropout作为一种**正则化**手段，也可以防止模型过拟合。

上面解释了模型在热启动和冷启动时是怎么处理的。此外，文章还提出了在冷启动后，用户或者项目开始产生少数的preference信息的时候应该怎么处理，这样才能让不同阶段无缝衔接。

以往处理这种准冷启动问题也很复杂，因为它既不是冷启动，但是可用的preference信息也十分稀少。而更新一次latent model是比较费时的，不能说来一些preference信息就更新一次，再来推荐。所以本文给出了一种简单的方法，用user交互过的那少数几个item的向量的平均，来代表这个user的向量。他们称这个过程为**transformation**。所以，用户有一些交互之后，先这样transform一下，先拿去用，后台慢慢地更新latent model，等更新好了，再换成latent model来进行推荐。

所以，作者在模型训练的时候，还增加了这样的一个transform过程。

这样，整体的训练算法就是这样的：

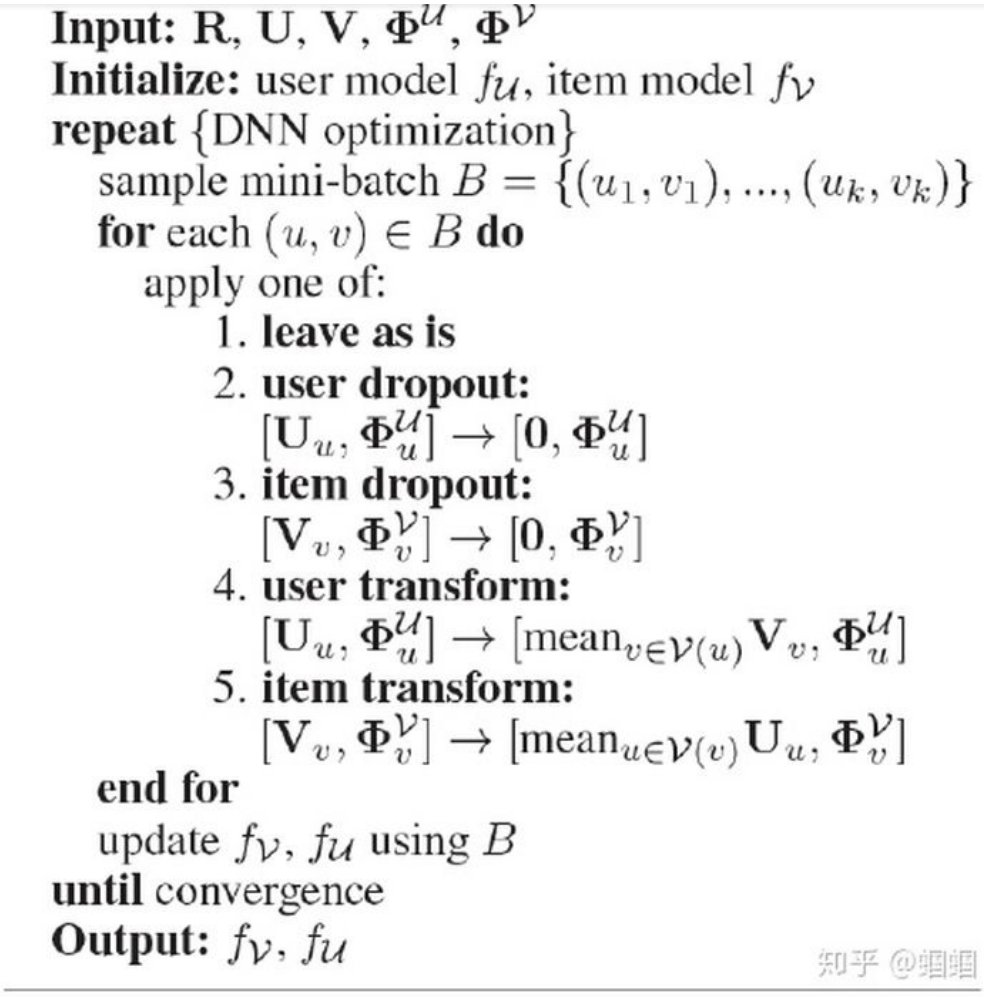

IV. 实验 & 结果展示

训练过程是这样的，我们有N个users和M个items，所以理论上可以形成N×M个样本。

设定一个**mini-batch**，比如100，每次抽100个user-item pair，设定一个**dropout rate**，例如0.3，则从100个用户中选出30个pair。对于这30个pair，我们**轮流使用dropout和transform来处理后输入DNN**，其余的70个则直接输入DNN。

接下来看看实验。

实验使用的数据集是一个科学文章数据库，用户可以在上面收藏各种文章，系统也会向用户推荐文章。

文章的content向量是tf-idf向量，用户由于没有content信息因此忽略了。另外，preference矩阵$\mathbf{R}$稀疏程度达到99.8%，因为平均每个用户收藏文章30多篇，而数据集中有一两万篇

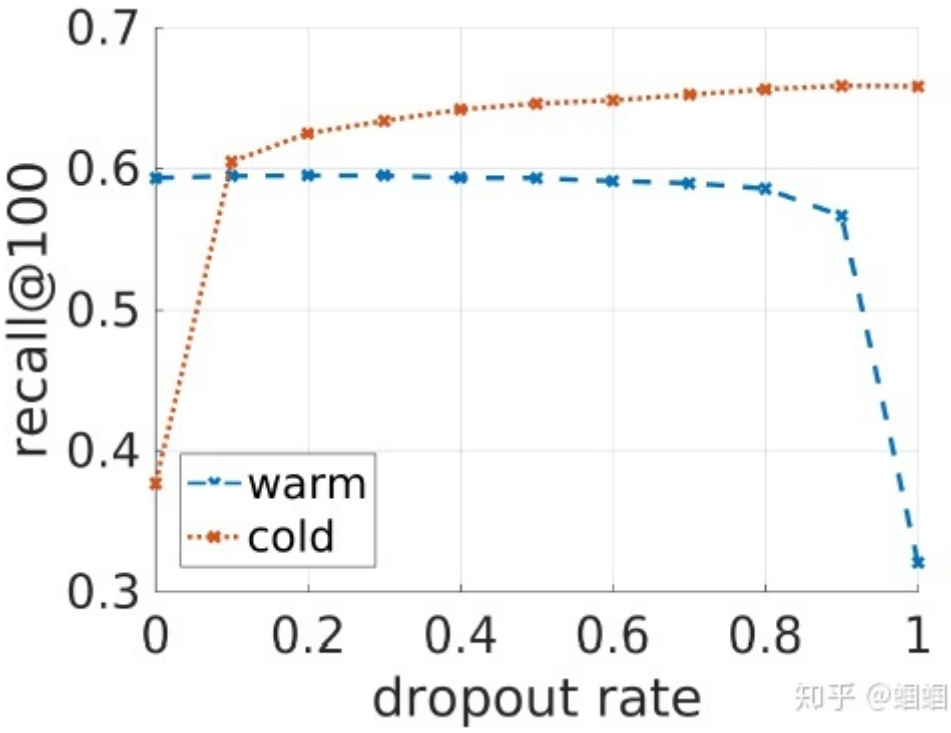

可以看出来cold start问题中，使用dropout可以大大提升推荐性能。但是过高的dropout rate会影响warm start的性能。

另外，作者也将模型和之前的一些模型做了对比，其中：

CTR和CDL是hybrid model，WMF是latent model，DeepMusic则是一个content model。

作者还提到他们模型的另一大优点就是，可以轻松地结合到之前的其他模型上，所以，作者将它们的模型和WMF以及CDL结合，称为**DN-WMF**和**DN-CDL**。对比如下：

知乎

WMF [13]	0.592	·
CTR [21]	0.597	0.589
DeepMusic [7]	0.371	0.601
CDL [22]	**0.603**	0.573
DN-WMF	0.593	**0.636**
DN-CDL	0.598	0.629

可以看到，在cold start中，DN-WMF取得了最佳效果，而且**DN-WMF**和**DN-CDL**都超过了之前的模型。这个不意外。

在warm start中，**DN-WMF**和**DN-CDL**稍稍逊色于以往的模型，这时hybrid model取得了最佳效果，但是确实差距很小。但是考虑到**DN-WMF**和**DN-CDL**的模型比hybrid模型简单地多，所以基本扯平。

值得注意的是这个**DeepMusic**，这是一个**纯content-based model**，意思是不使用preference信息。可以看到，**在warm start这种有着丰富preference信息的环境下，它的效果远不如利用preference的其他模型**。而在cold start这种没有preference信息的情况下，效果就超过了hybrid model。这个时候WMF这种纯靠preference根本不能算了。这也就解释了，为什么前面的目标函数要以preference-based的latent model为标杆了。

在另外一个数据集上的结果这里直接放出，就不赘述了：