Bo_hemian
归纳以知新

FFM算法解析及Python实现

1. 什么是FFM?

通过引入field的概念，FFM把相同性质的特征归于同一个field，相当于把FM中已经细分的feature再次进行拆分从而进行特征组合的二分类模型。

2. 为什么需要FFM?

在传统的线性模型中，每个特征都是独立的，如果需要考虑特征与特征之间的相互作用，可能需要人工对特征进行交叉组合。非线性SVM可以对特征进行核变换，但是在特征高度稀疏的情况下，并不能很好的进行学习。由于推荐系统是一个高度系数的数据场景，由此产生了FM系列算法，包括FM，FFM，DeepFM等算法。

3. FFM用在哪?

和FM算法一样，FFM主要应用在推荐算法中的CTR点击率预估（排序）问题，推荐系统一般可以分成两个模块，召回和排序。比如对于电影推荐，召回模块会针对用户生成一个推荐电影列表，而排序模块则负责对这个电影列表根据用户的兴趣做排序。当把FFM算法应用到推荐系统中时，具体地是应用在排序模块。

4. FFM长什么样?

FFM模型结构

$$y(\mathbf{x}) = w_0 + \sum_{i=1}^{n} w_i x_i + \sum_{i=1}^{n} \sum_{j=i+1}^{n} \langle \mathbf{v}_{i,f_j}, \mathbf{v}_{j,f_i} \rangle x_i x_j$$

线性　　非线性（交叉特征）

线性部分大家都很熟悉，非线性部分是FFM的关键所在，并且与同样有非线性部分的FM算法相比，FFM引入了field的概念。因此交叉项与FM算法的<vi , vj>不同，这里的是<vi,fj , vj,fi>

5. FFM交叉项的计算

以下图网上流传广泛的图为例：

Field 1	Field 2	Field 3		Field 4
User	Movie	Genre		Price
YuChin	3Idiots	Comedy, Drama		$9.99
Value 1	Value 2	Value 3	Value 4	Value 5

其中，红色部分对应的是Field，来自于原始特征的个数；
蓝色部分对应的是feature，来自于原始特征onehot之后的个数。(连续型特征不用one-hot)
对于特征Feature:User=YuChin，有Movie=3Idiots、Genre=Comedy、Genre=Drama、Price四项要进行交叉组合：

$$\langle \mathbf{v}_{1,2}, \mathbf{v}_{2,1} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{1,3}, \mathbf{v}_{3,1} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{1,3}, \mathbf{v}_{4,1} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{1,4}, \mathbf{v}_{5,1} \rangle \cdot 1 \cdot 9.99$$

绿色部分为对应特征one-hot之后的值，出现为1，不出现为0。对于连续型变量的处理，这里采用的是使用实际值，当然，也可以对连续型变量离散化处理，再进行one-hot。

$$\begin{aligned}\langle \mathbf{v}_{1,2}, \mathbf{v}_{2,1} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{1,3}, \mathbf{v}_{3,1} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{1,3}, \mathbf{v}_{4,1} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{1,4}, \mathbf{v}_{5,1} \rangle \cdot 1 \cdot 9.99 \\ + \langle \mathbf{v}_{2,3}, \mathbf{v}_{3,2} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{2,3}, \mathbf{v}_{4,2} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{2,4}, \mathbf{v}_{5,2} \rangle \cdot 1 \cdot 9.99 \\ + \langle \mathbf{v}_{3,3}, \mathbf{v}_{4,3} \rangle \cdot 1 \cdot 1 + \langle \mathbf{v}_{3,4}, \mathbf{v}_{5,3} \rangle \cdot 1 \cdot 9.99 \\ + \langle \mathbf{v}_{4,4}, \mathbf{v}_{5,3} \rangle \cdot 1 \cdot 9.99\end{aligned}$$

6. FFM代码分析

这里我们的FFM算法是基于Tensorflow实现的。

为什么用Tensorflow呢？观察二次项，由于field的引入，Vffm需要计算的参数有 nfk 个，远多于FM模型的 nk 个，而且由于每次计算都依赖于乘以的xj的field，所以，无法用fm的计算技巧(ab = 1/2(a+b)^2-a^2-b^2)，所以计算复杂度是 O(n^2)。

因此使用Tensorflow的目的是想通过GPU进行计算。同时这也给我们提供了一个思路：如果模型的计算复杂度较高，当不能使用CPU快速完成模型训练时，可以考虑使用GPU计算。比如Xgboost是已经封装好可以用在GPU上的算法库，而那些没有GPU版本的封装算法库时，例如我们此次采用的FFM算法，我们可以借助Tensorflow的GPU版本框架设计算法，并完成模型训练。

代码主要分三部分：

build_data.py

主要是完成对原始数据的转化。主要包括构造特征值对应field的字典。

FFM.py

主要包括线性部分及非线性部分的代码实现。

tools.py

主要包括训练集的构造。

这里我们主要分析 FFM.py，也就是模型的构建过程：

首先初始化一些参数，包括：

- k：隐向量长度
- f：field个数
- p：特征值个数
- 学习率大小
- 批训练大小
- 正则化
- 模型保存位置等

代码如下图所示：

```
class Args(object):
    # number of latent factors
    k = 6
    # num of fields
    f = 24
    # num of features
    p = 100
    learning_rate = 0.1
    batch_size = 64
    l2_reg_rate = 0.001
    feature2field = None
    checkpoint_dir = 'F:/Projects/machine_learning/FFM/data/ffm/saver'
    is_training = True
    epoch = 1
```

然后，构造了一个model类，主要存放：

- 初始化的一些参数
- 模型结构
- 模型训练op（参数更新）

- 预测op
- 模型保存以及载入的op

代码如下图所示：

```
class Model(object):
    def __init__(self, args):...

    def build_model(self):...

    def train(self, sess, x, label):...

    def cal(self, sess, x, label):...

    def predict(self, sess, x):...

    def save(self, sess, path):...

    def restore(self, sess, path):
        saver = tf.train.Saver()
        saver.restore(sess, save_path=path)
```

之后，对模型构造部分代码进行分析，可发现模型由两部分组成，第一部分是下图红框内容，其实就是线性表达式 w^Tx+b，其中：

- b shape(None,1)
- x shape (batch_size,p)
- w1 shape(p,1)　注：p为特征值个数

定义变量及初始化后，就可以构造线性模型，代码如下图所示：

```
def build_model(self):
    self.X = tf.placeholder('float32', [self.batch_size, self.p])
    self.y = tf.placeholder('float32', [None, 1])

    # linear part
    with tf.variable_scope('linear_layer'):
        b = tf.get_variable('bias', shape=[1],
                            initializer=tf.zeros_initializer())
        self.w1 = tf.get_variable('w1', shape=[self.p, 1],
                                  initializer=tf.truncated_normal_initializer(mean=0, stddev=0.01))
        # shape of [None, 1]
        self.linear_terms = tf.add(tf.matmul(self.X, self.w1), b)
        print('self.linear_terms:')
        print(self.linear_terms)
```

然后，定义一个Vffm变量用来存放交叉项的权重，并初始化。因为我们已经了解到Vffm是一个三维向量，所以，v： shape(p,f,k) 。

之后是vi,fj、vj,fi的构造。因为v 有p行，代表共有p个特征值，所以vifj = v[i, feature2field[j]]，说人话就是第i个特征值在第j个特征值对应的field上的隐向量。

vjfi 的构造方法类似，所以vivj就可以求出来.然后就是把交叉项累加，然后 reshape 成（batch_size，1）的形状，以便与线性模型进行矩阵加法计算。

代码如下图所示：

```
with tf.variable_scope('nolinear layer'):
    self.v = tf.get_variable('v', shape=[self.p, self.f, self.k], dtype='float32',
                             initializer=tf.truncated_normal_initializer(mean=0, stddev=0.01))
    # v:pxfxk
    self.field_cross_interaction = tf.constant(0, dtype='float32')
    # 每个特征求交叉项
    for i in range(self.p):
        for j in range(i + 1, self.p):
            print('i:%s,j:%s' % (i, j))
            vifj = self.v[i, self.feature2field[j]] # shape=(1,6)
            print('vifj:',vifj)
            vjfi = self.v[j, self.feature2field[i]]
            vivj = tf.reduce_sum(tf.multiply(vifj, vjfi))
            xixj = tf.multiply(self.X[:, i], self.X[:, j])
            self.field_cross_interaction += tf.multiply(vivj, xixj)
    self.field_cross_interaction = tf.reshape(self.field_cross_interaction, (self.batch_size, 1))
    print('self.field_cross_interaction:')
    print(self.field_cross_interaction)
self.y_out =  tf.add(self.linear_terms, self.field_cross_interaction)
print('y_out_prob:')
print(self.y_out)
```

下图描述了所有交叉项的隐向量Vffm所处的位置。假设p=16、f=3、k=6，16个项所属的field为{0: 0, 1: 0, 2: 0, 3: 0, 4: 0, 5: 0, 6: 1, 7: 1, 8: 1, 9: 1, 10: 2, 11: 2, 12: 2, 13: 2, 14: 2, 15: 2}，共有120个交叉项，vifj和vjfi隐向量分别各有120个。其中：

vifj隐向量： {(3, 0), (11, 2), (2, 1), (6, 2), (5, 1), (7, 2), (4, 0), (1, 2), (12, 2), (8, 1), (2, 2), (4, 1), (1, 1), (3, 2), (0, 0), (13, 2), (8, 2), (7, 1), (4, 2), (1, 0), (14, 2), (0, 1), (9, 2), (6, 1), (3, 1), (2, 0), (5, 2), (0, 2), (10, 2)}，共29个不同的隐向量。
vjfi隐向量： {(12, 1), (9, 1), (3, 0), (11, 2), (8, 0), (15, 1), (14, 0), (4, 0), (12, 2), (9, 0), (8, 1), (15, 0), (14, 1), (11, 1), (5, 0), (10, 0), (13, 2), (7, 1), (6, 0), (11, 0), (10, 1), (1, 0), (14, 2), (13, 1), (7, 0), (15, 2), (12, 0), (2, 0), (13, 0)}，共29个不同的隐向量。

而vifj和vjfi相加起来共有48个各不相同的隐向量。也就是说，下图展示的每一个隐向量都有用，即都能在模型中找到，且很多交叉项的隐向量一样。

举个栗子：

v1,15代表着第1个特征值在第15个特征值对应的field（field=2）上的隐向量。即v1,15 = v[1, feature2field[15]] = Vffm[1,2]，其中v1,15的shape = (1,6)。

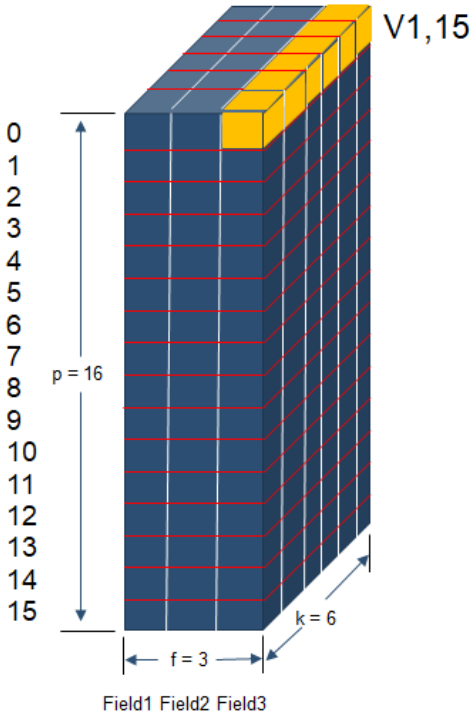

最后，就是loss的定义。这里要注意我们之前在构造训练集时已经把输出的（0，1）分类转化为（-1，1）分类。

```
# -1/1情况下的logistic loss
self.loss = tf.reduce_mean(tf.log(1 + tf.exp(-self.y * self.y_out)))

# 正则：sum(w^2)/2*l2_reg_rate
# 这边只加了weight，有需要的可以加上bias部分
self.loss += tf.contrib.layers.l2_regularizer(self.l2_reg_rate)(self.w1)
self.loss += tf.contrib.layers.l2_regularizer(self.l2_reg_rate)(self.v)
self.global_step = tf.Variable(0, trainable=False)
opt = tf.train.GradientDescentOptimizer(self.learning_rate)
trainable_params = tf.trainable_variables()
print(trainable_params)
gradients = tf.gradients(self.loss, trainable_params)
clip_gradients, _ = tf.clip_by_global_norm(gradients, 5)
self.train_op = opt.apply_gradients(
    zip(clip_gradients, trainable_params), global_step=self.global_step)
```

核心加重点是关注loss的计算公式，此时的计算公式是-1/1做二分类的时候常用的loss计算方法。

$$\min_{\mathbf{w}} \sum_{i=1}^{L} \log\left(1+\exp\{-y_i \phi(\mathbf{w}, \mathbf{x}_i)\}\right) + \frac{\lambda}{2}\|\mathbf{w}\|^2$$

7. 总结

7.1 FFM 算法流程

7.1.1 输入部分

1. 类别型特征对应的变量的值映射为0到n-1
2. 连续型变量保持原样，不做处理，只需把变量名映射为n即可。（也可按实际情况进行离散化处理）
3. 根据每一特征所属的field，构造字典：每一field的取值，例如：field为0，那么{0：0，0：1，0：2}。key为field，value为变量值或变量名的映射
4. 构造feature2field字典，本质就是把步骤3中的field字典的k-v交换位置
5. 最终模型的输入数据为（None，n+1），其中n个离散变量的特征，取值为0/1，1个连续变量的特征，取值为连续值（需要归一化）

7.1.2 输出部分

1. 输出y 由0/1分类转换为-1/1分类
2. 构造字典{1：n+2，-1：n+3}作为输出
3. 构造训练集需要的字典field_dict，包括输入数据和输出数据，例如：{'c1':{1008:0,1001:1}，'c2':{0:6,1:7}}

7.2 注意事项

1. 原始FFM论文中的结论：隐向量的维度 k值的调整提升效果不明显。

k	time	logloss
1	27.236	0.45773
2	26.384	0.45715
4	27.875	0.45696
8	40.331	0.45690
16	70.164	0.45725

(a) The average running time (in seconds) per epoch and the best logloss with different values of k. Because we use SSE instructions, the running time of $k = 1, 2, 4$ is roughly the same.

2. 为了使用FFM方法，所有的特征必须转换成“field_id:feat_id:value”格式，field_id代表特征所属field的编号，feat_id是特征编号，value是特征的值。
3. numerical数值型的特征比较容易处理，只需分配单独的field编号，如用户评论得分、商品的历史CTR/CVR等。优点是快速简单，不需要预处理，但是缺点也很明显，离群点影响，值的波动大等。因此可对numerical数值型特征采用连续值离散化或分箱下的连续值离散化的方法，将其转化为categorical类别型特征。
4. categorical类别型特征需要经过One-Hot编码成数值型，编码产生的所有特征同属于一个field，而特征的值只能是0或1，如用户的性别、年龄段，商品的品类id等。

5. 样本归一化。FFM默认是进行样本数据的归一化，若不进行数据样本的归一化，很容易造成数据inf溢出，进而引起梯度计算的nan错误。因此，样本层面的数据是推荐进行归一化的。

6. 特征归一化。CTR/CVR模型采用了多种类型的源特征，包括数值型和categorical类型等。但是，categorical类编码后的特征取值只有0或1，较大的数值型特征会造成样本归一化后categorical类生成特征的值非常小，没有区分性。例如，一条用户-商品记录，用户为“男”性，商品的销量是5000个（假设其它特征的值为零），那么归一化后特征“sex=male”（性别为男）的值略小于0.0002，而“volume”（销量）的值近似为1。特征“sex=male”在这个样本中的作用几乎可以忽略不计，这是相当不合理的。因此，将源数值型特征的值归一化也是非常必要的。

7. 省略零值特征。从FFM模型的表达式可以看出，零值特征对模型完全没有贡献。包含零值特征的一次项和组合项均为零，对于训练模型参数或者目标值预估是没有作用的。因此，可以省去零值特征，提高FFM模型训练和预测的速度，这也是稀疏样本采用FFM的显著优势。

8. 参考文献

[1] 深入FFM原理与实践

[2] FM系列算法解读（FM+FFM+DeepFM）

[3] 推荐算法之FFM：原理及实现简介

标签: CTR , 机器学习

« 上一篇： pandas：对字符串类型做差分比较
» 下一篇： pandas：apply和transform方法的性能比较

posted @ 2018-10-21 00:28 Bo_hemian 阅读(8312) 评论(5) 编辑 收藏

评论列表

#1楼 2018-11-09 16:44 **魔箭GG**

请问完整的程序在哪里呀，能不能发一份到我的邮箱，多谢！
623991984@qq.com

支持(0) 反对(0)

#2楼 2019-04-18 09:22 **lhbky425**

博主您好打搅了，看了您写的解读非常详细，收获很多，想结合FFM的代码运行以下，希望您能在闲余之时分享一份FFM代码和数据集，万分的感谢！！！
邮箱：824002466@qq.com

支持(0) 反对(0)

#3楼 2019-06-03 15:14 **书洛**

博主，您好。万分感谢您的详细解读，对于我这个初入门的小白帮助很大，请问您能否分享一下代码和数据集，万分感谢！
邮箱：1758879669@qq.com

支持(0) 反对(0)

#4楼 2019-08-25 09:49 **Millyliu**

感谢博主的分享，针对这个方向想要深入了解进一步学习，希望能分享一下完整的代码和相应的数据集，非常感谢！
785965196@qq.com

支持(0) 反对(0)

#5楼 2019-11-16 10:46 **muzichuan**