

# FFM: 将相同特性的特征归到同一Field的「领域意识」因子分解机, 相比于FM, 其优势在哪?

原创 去远方看太阳 随时学丫 3月24日



这是小婵的第 10 期分享

作者 | 小婵

来源 | 小婵 (ID: a18581391726)

转载请联系授权 | (微信ID: a18581391726)

本文共 1705 字, 预计阅读需 5 分钟

FFM 算法, 全称是 Field-aware Factorization Machines, 是 FM (Factorization Machines) 的改进版。FFM 最初的概念来自 Yu-Chin Juan (阮毓钦, 毕业于中国台湾大学, 现在美国 Criteo 工作) 与其比赛队员。通过引入 field 的概念, FFM 把相同性质的特征归于同一个 field。

在 FFM 中, 每一维特征  $x_i$ , 针对其它特征的每一种 field  $f_j$ , 都会学习一个隐向量  $V_{i,f_j}$ 。因此, 隐向量不仅与特征相关, 也与 field 相关。这也是 FFM 中 “Field-aware” 的由来。

## FFM 相比于 FM, 做了哪些优化?

### 回顾一下 FM

$$\hat{y} = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n v_i \cdot v_j x_i x_j$$

微信号:zh\_ssx\_1314520

样本  $x$  是  $n$  维向量， $x_i$  是第  $i$  个维度上的值。 $v_i$  是  $x_i$  对应的长度为  $K$  的隐向量， $V$  是模型参数，所以所有样本都使用同一个  $V$ ，即  $x_{1,1}$  与  $x_{2,1}$  都使用  $v_1$ 。

FFM 中的 Field

在 FFM 中，每一维特征 feature 都归属于一个特定的 field，field 和 feature 是一对多关系。

filed	field1=年龄	field2=城市			field3=性别	
feature	x1=年龄	x2=北京	x3=上海	x4=深圳	x5=男	x5=女
user1	23	1	0	0	1	0
user2	25	0	1	0	0	1

对于连续特征，一个特征就对应一个 Field，或者对连续特征离散化，一个分箱成为一个特征，比如：

filed	field1=年龄			
feature	<20	20-30	30-40	>40
user1	0	1	0	0
user2	0	1	0	0

对于离散特征，采用 One-Hot 编码，同一属性的归到一个 Field，不论是连续特征还是离散特征，它们都有一个共同点：同一个 field 下只有一个 feature 的值不为 0，其它 feature 的值都为 0。

FFM 模型认为  $v_i$  不仅跟  $x_i$  有关系，还跟与  $x_i$  相乘的  $x_j$  所属的 field 有关系，即  $v_j$  成了一个二维向量  $v_{F,K}$ ， $F$  是 field 的总个数，FFM 只保留了 FM 式子中的二次项。

$$\hat{y} = \sum_{i=1}^n \sum_{j=i+1}^n v_{i,f_j} \cdot v_{j,f_i} x_i x_j$$

以上文的表格数据为例，计算 user1 的  $\hat{y}$ 。

$$\hat{y} = v_{1,f_2} \cdot v_{2,f_1} x_1 x_2 + v_{1,f_3} \cdot v_{3,f_1} x_1 x_3 + v_{1,f_4} \cdot v_{4,f_1} x_1 x_4 + \dots$$

由于  $x_2, x_3, x_4$  属于同一个 field，所以  $f_2, f_3, f_4$  可以用同一个变量来代替，比如就用  $f_2$ 。

$$\hat{y} = v_{1,f_2} \cdot v_{2,f_1} x_1 x_2 + v_{1,f_2} \cdot v_{3,f_1} x_1 x_3 + v_{1,f_2} \cdot v_{4,f_1} x_1 x_4 + \dots$$

我们来算一下  $\hat{y}$  对  $v_{1,f_2}$  的偏导。

$$\frac{\partial \hat{y}}{\partial v_{1,f_2}} = v_{2,f_1} x_1 x_2 + v_{3,f_1} x_1 x_3 + v_{4,f_1} x_1 x_4$$

等式两边都是长度为  $K$  的向量。

注意  $x_2, x_3, x_4$  是同一个属性的 one-hot 表示, 即  $x_2, x_3, x_4$  中只有一个为 1, 其他都为 0。在本例中  $x_3 = x_4 = 0, x_2 = 1$ , 所以

$$\frac{\partial \hat{y}}{\partial v_{1,f_2}} = v_{2,f_1} x_1 x_2$$

推广到一半情况:

$$\frac{\partial \hat{y}}{\partial v_{i,f_j}} = v_{j,f_i} x_i x_j$$

$x_j$  属于 Field  $f_j$ , 且同一个 Field 里面的其他  $x_m$  都等于 0。实际项目中  $x$  是非常高维的稀疏向量, 求导时只关注那些非 0 项即可。

你一定有个疑问:  $v$  是模型参数, 为了求  $v$  我们采用梯度下降法时需要计算损失函数对  $v$  的导数, 为什么这里要计算  $\hat{y}$  对  $v$  的导数?

在实际预测点几率的项目中, 我们是不会直接使用公式  $\hat{y} = \sum_{i=1}^n \sum_{j=i+1}^n v_{i,f_j} \cdot v_{j,f_i} x_i x_j$  的, 通常会再套一层 sigmoid 函数, 公式中的  $\hat{y}$  用  $z$  来取代。

$$z = \phi(v, x) = \sum_{i=1}^n \sum_{j=i+1}^n v_{i,f_j} \cdot v_{j,f_i} x_i x_j$$

由  $\frac{\partial \hat{y}}{\partial v_{1,f_j}} = v_{2,f_j} x_1 x_j$  得

$$\frac{\partial z}{\partial v_{i,f_j}} = v_{j,f_i} x_i x_j$$

用  $a$  表示对点击率的预测值

$$a = \sigma(z) = \frac{1}{1+e^{(-z)}} = \frac{1}{1+e^{(-\phi(v,x))}}$$

令  $y=0$  表示负样本,  $y=1$  表示正样本,  $C$  表示交叉熵损失函数。根据神经网络调优公式可得:

$$\frac{\partial C}{\partial z} = a - y = \begin{cases} -\frac{1}{1+e^z} & \text{if } y \text{ 是正样本} \\ \frac{1}{1+e^{-z}} & \text{if } y \text{ 是负样本} \end{cases}$$

$$\frac{\partial C}{\partial v_{i,fj}} = \frac{\partial C}{\partial z} \frac{\partial z}{\partial v_{i,fj}} \quad \text{微信号: zb_ssx_1314520}$$

看完了本博客再去看论文《Field-aware Factorization Machines for CTR Prediction》中的公式推导应该就比较容易了吧, 在该论文中他是以  $y=1$  代表正样本,  $y=-1$  代表负样本, 所以才有了 3.1 节中的  $k = \frac{\partial C}{\partial z} = \frac{-y}{1+e^{(yz)}}$

有了上面的推导, 我们再来看 FFM 的公式。

设样本一共有  $n$  个特征,  $f$  个 field, 那么, FFM 的二次项有  $nf$  个隐向量。而在 FM 模型中, 每一维特征的隐向量只有一个。FM 可以看做 FFM 的特例, 是把所有特征都归属到一个 Field 时的 FFM 模型。根据 FFM 的 Field 敏感特性, 可以导出其模型方程。

$$y = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n v_{i,j_j} v_{j,f_i} x_i x_j \quad \text{微信号: zb_ssx_1314520}$$

其中,  $f_j$  是第  $j$  个特征所属的字段, 如果隐向量的长度为  $k$ , 那么 FFM 的二次参数有  $nfk$  个, 远远多于 FM 模型的  $nk$  个, 此外, 由于隐向量与 Field 相关, FFM 二次项并不能够化简, 时间复杂度是  $O(kn^2)$ 。

需要注意的是由于 FFM 中的 latent vector 只需要学习特定的 Field, 所以通常:  $KFFM \ll KFM$ 。

FFM 由于引入了 Field, 使得每两组特征交叉的隐向量都是独立的, 可以取得更好的组合效果, FM 可以看做只有一个 Field 的 FFM。

FFM的论文地址: <https://www.csie.ntu.edu.tw/~cjlin/papers/ffm.pdf>

END