一镜到底：FM们的原理及在贝壳搜索的实践

原创 智能搜索团队 贝壳智搜 2019-07-02

一、背景

在推荐系统、搜索排序、效果广告等场景中，点击率预估是十分重要的部分，CTR算法也被誉为镶嵌在互联网技术上的明珠。在深度学习火热之前，除了简单的LR以外常用的算法类有：以决策树为主的Boosting算法；以因子分解为基础的 FM 算法。相对而言，树模型比较适合学习数值类的连续特征，而后者更适合学习ID类（Categorical ）的稀疏特征。深度学习横空出世之后，更多的研究者把重心放在如何将 Deep Learning 运用于CTR 任务，比较著名的有Google 开源的Wide and Deep 算法和 DCN 网络。通常来说，FM-based 算法更适合深度学习，深度学习需要海量的训练数据，大量稀疏的 ID 类特征为深度学习提供绝佳的土壤。

FM 的主要目的是解决稀疏特征下参数学习问题，可以实现树模型不能学习的特征交叉。本文主要涉及几个以 FM 为基础的算法。本着学习交流分享精神，本文从FM出发，梳理一下这些以FM为基础的算法。如有纰漏，敬请指出。

二、传统FM

2.1 FM原理

可能很多人和我一样最先接触到的并不是 FM，而是 LR、贝叶斯和决策树这些广义线性模型。在传统的线性模型中，每一维度的特征都是独立处理，当需要考虑特征与特征之间的相互作用，必须要对这些特征进行人工处理来进行交叉组合。在点击率预告的问题中通常包含着大量 ID 类特征，送入树模型中通常需要进行 onehot 编码。通过用户点击投放房屋的情况，简单介绍下 onehot 编码

点击	用户	小区	价格(万)	面积(平方)
1	A	x	100	80
0	B	y	60	50
0	A	x	90	70
1	C	z	200	100

对 ID 类特征进行编码之后，特征变为

点击	用户=A	用户=B	用户=C	小区=x	小区=y	小区=z	价格	面积
1	1	0	0	1	0	0	100	80
0	0	1	0	0	1	0	60	50
0	1	0	0	1	0	0	90	70
1	0	0	1	0	0	1	200	100

当数据量到达千万条以上时，将特征进行交叉组合是一个十分耗时和消耗资源的过程。并且模型在学习时会产生大量的参数，如果把 m 维的特征和 n 维的特征进行交叉将产生 mxn个参数，加大了模型过拟合的风险。更为重要的是在特征十分稀疏的情况下，LR 和 XGB 等模型也很难学习特征之间的交叉信息，这也是因子分解机最主要的目的。

简单介绍下因子分解机的原理。我们首先考虑一个多项式模型，并对模型进行二元交叉可以得到下面的式子

$$f(x) = w_0 + \sum_{i=1}^{n} w_i \cdot x_i + \sum_{i=1}^{n} \sum_{j=i+1}^{n} w_{ij} \cdot x_i x_j$$

其中 $\boldsymbol{x}$ 表示特征，$\boldsymbol{n}$ 代表特征维度，$\boldsymbol{w}$ 表示系数。很容易得出参数$\boldsymbol{w}_{ij}$的个数为 n(n-1)/2，当特征维度 n 很大时参数矩阵 $\{\boldsymbol{w}_{ij}\}$几乎不可计算。思考下原因，在多项式模型中$\boldsymbol{w}_{ij}$代表的是两个特征之间的系数，在特征十分稀疏（大部分$\boldsymbol{x}$ 的值为0）的情况下直接学习参数效率低下。FM提出用 $\boldsymbol{k}$ 维隐向量作为来表示特征，这 $\boldsymbol{k}$ 个值都是表示特征的因子，因此被称为因子分解机，其公式如下所示

$$f(x) = w_0 + \sum_{i=1}^{n} w_i \cdot x_i + \sum_{i=1}^{n} \sum_{j=i+1}^{n} \left(v_i \cdot v_j\right) \cdot x_i x_j$$

其中 ***v*** 就代表 ***k*** 维的因子。这样就将 ***W={wij}*** 分解为$W = V^T V$的形式，这里$V = (v_1, v_2, \cdots, v_n)$就是一个$k \times n$的矩阵。然后我们惊奇的发现，需要训练的参数个数从 n(n-1)/2 降到 kn 。变换之后，将求解 ***W={wij}*** 的问题变成了求解$(v_i \cdot v_j)$。FM 算法中还有一个小技巧，利用变换对参数求解的过程进一步优化，具体的过程如下所示：

$$\sum_{i=1}^{n}\sum_{j=i+1}^{n}\left\langle \mathbf{v}_i, \mathbf{v}_j \right\rangle x_i x_j$$

$$=\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}\left\langle \mathbf{v}_i, \mathbf{v}_j \right\rangle x_i x_j - \frac{1}{2}\sum_{i=1}^{n}\left\langle \mathbf{v}_i, \mathbf{v}_i \right\rangle x_i x_i$$

$$=\frac{1}{2}\left(\sum_{i=1}^{n}\sum_{j=1}^{n}\sum_{f=1}^{k} v_{i,f} v_{j,f} x_i x_j - \sum_{i=1}^{n}\sum_{f=1}^{k} v_{i,f} v_{i,f} x_i x_i\right)$$

$$=\frac{1}{2}\sum_{f=1}^{k}\left(\left(\sum_{i=1}^{n} v_{i,f} x_i\right)\left(\sum_{j=1}^{n} v_{j,f} x_j\right) - \sum_{i=1}^{n} v_{i,f}^2 x_i^2\right)$$

$$=\frac{1}{2}\sum_{f=1}^{k}\left(\left(\sum_{i=1}^{n} v_{i,f} x_i\right)^2 - \sum_{i=1}^{n} v_{i,f}^2 x_i^2\right)$$

可能变换的第一步不好理解，首先我们知道 ***V*** 是一个对角阵，假设$A = \sum_{i=1}^{n}\sum_{j=i+1}^{n}\left\langle \mathbf{v}_i, \mathbf{v}_j \right\rangle x_i x_j$代表的就是上三角阵元素之和（这里 ***A*** 不包括对角线元素），$B = \sum_{i=1}^{n}\left\langle \mathbf{v}_i, \mathbf{v}_i \right\rangle x_i x_i$来表示对角线元素之和，同时整个矩阵之和可表示为$C = \sum_{i=1}^{n}\sum_{j=1}^{n}\left\langle \mathbf{v}_i, \mathbf{v}_j \right\rangle x_i x_j$。根据对角阵的性质我们可以得到C = (2A + B)，那么 A 就可以表示为 A=C/2 - B/2。

在训练 FM 时，也可以和 LR 算法一样可以利用 SGD（随机梯度下降）来求解参数，各个参数的梯度如下：

$$\frac{\partial}{\partial\theta}\hat{y}(\mathbf{x}) = \begin{cases} 1, & \text{if } \theta \text{ is } w_0 \\ x_i, & \text{if } \theta \text{ is } w_i \\ x_i \sum_{j=1}^{n} v_{j,f} x_j - v_{i,f} x_i^2, & \text{if } \theta \text{ is } v_{i,f} \end{cases}$$

在模型中， $\sum_{j=1}^{n} v_{j,f} x_j$ 只和 f 有关，因此在每次迭代中，只需要计算一次就可以得到所有的梯度。原本 FM 的复杂度为 $O\left(kn^2\right)$ ，通过上面等式的变换将其二次项化简为 ***v{i, f}*** 有关的等式，模型的复杂度降为 $O\left(kn\right)$。从梯度计算的公式也可以看出，当特征值为0时时梯度也为0，值为0的特征放到模型中训练没有意义，因此可以忽略0值， 这样一来 FM 就可以很快学习极其稀疏的特征。

2.2 FFM

FFM 是 FM的一个变种，可以说是加强版，基本的框架和 FM 一致，再其基础之上引入了域的概念。首先强推美团技术团队的《深入FFM原理与实践》和作者的 Slides ，看完这些就可以了解FFM的基本原理。FFM的全称是Field-aware Factorization Machine，是在因子分解机的基础之上引入了域（filed）的概念。FM 有一个很明显的缺点，它不加区分的对待每一个特征，忽略了某一类特征之间的共性。FFM 认为，由同一个 ID 类特征通过onehot编码产生的特征，或者其他特征变换获得的特征，应该同属于一个特殊的集合域，不同的特征和同一个域关联时需要使用不同的隐向量。假如我们一个有 d 个特征和 f 个域，那么每个特征需要用 f 个隐变量表示，也就是一共有 d x f 个隐向量。从 FFM 的公式也可以看出，

$$f(x) = w_0 + \sum_{i=1}^{d} w_i \cdot x_i + \sum_{i=1}^{d} \sum_{j=i+1}^{d} \left(v_{i,f_j} \cdot v_{j,f_i}\right) \cdot x_i x_j$$

同样是上面用户点击房子的例子，在 FFM 中特征可以表示为

Field name	Field index	Feature name	Feature index
用户	1	A	1
		B	2

Field name	Field index	Feature name	Feature index
		C	3
小区	2	x	4
		y	5
		z	6
价格	3	price	7
面积		area	8

仿造libSVM的格式，FFM 的作者设计了libFFM的数据格式，如下所示

label field1: feature1: value1 field2:feature2:value2

经过简单的归一化和零值处理之后，上面的例子可以表示为

1 1:1:1 2:4:1 3:7:0.5. 4:8:0.8
0 1:2:1 2:5:1 3:7:0.3 4:8:0.5
0 1:1:1 2:4:1 3:7:0.45 4:8:0.7
1 1:3:1 2:6:1 3:7:1.0 4:8:1.0

进一步的原理不再介绍，和 FM 大同小异，相对于 FM 而言，FFM 的设计更为复杂与合理。简单的来说，FM 是两个特征之间的直接交叉，FFM更近一步特征是和域进行交叉。当只有一个域的时候，FFM 等价于 FM，也就是说其实 FM 是 FFM 把特征都归为一个域的特例。FFM 的基本原理就不在赘述，有兴趣的可以好好看看上面推荐的两个链接。

下面分享下使用FFM的一些注意事项：

1. 归一化、归一化、归一化（重要的事情说三遍！！！），包括样本归一化和特征归一化；
2. 特征编号，libffm特征的格式为 field:index:value，有些封装好的模型包field编号从0开始，有些从1开始；
3. 每一列的特征编号尽量不要重叠，libffm中不允许重叠；
4. 可以省略value为0的项，零值特征对模型训练没有任何贡献；

5. 推荐使用xLearn，速度十分的快。

2.3 开源工具

目前有很多开源的因子分解机工具包，主要有libfm，libffm，xLearn 和 tffm。

工具包	语言	GitHub	特性
libfm	C++	https://github.com/srendle/libfm	最早的 FM 工具包，由算法的提出者编写
libffm	C++	https://github.com/ycjuan/libffm	FFM 提出者编写的工具包
xLearn	C++	https://github.com/aksnzhy/xlearn	性能强，易扩展
tffm	Python	https://github.com/geffy/tffm	基于 Tensorflow 实现

xLearn 是一个十分有用的机器学习工具包，由北京大学信息科学技术学院开源。目前 xLearn 已经集成了三种经典的算法，包括LR，FM和FFM，适用于广告点击率预测、推荐系统等多种场景。相比与其他工具包，它的优势在于性能好和简单易用。作者在单台 MacBook 上测试，xLearn 性能远远超过其他工具包，同时提供 out-of-core 计算，利用外存计算可以在单机处理 1TB 数据，并且支持分布式训练。另外一个令人欣喜的是，xLearn提供了python接口，调用起来十分的方便。

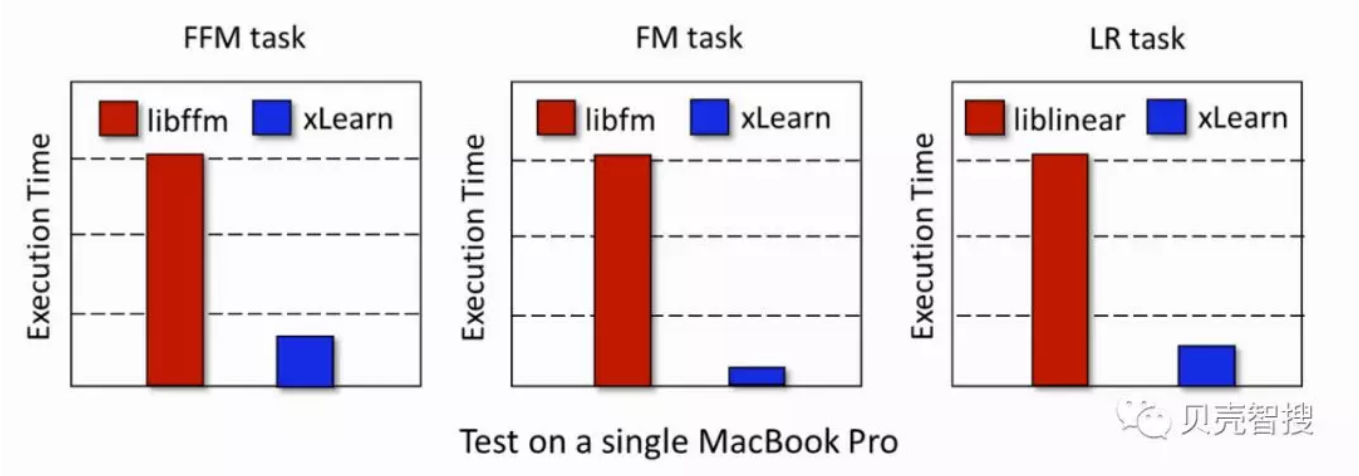

接下来将用我司（贝壳找房）真实小批量原始数据集上进行实验，其中field数量为34，特征维度为1407926。以下试验均省略掉构建 FM 和 FFM 特定的训练文件的过程，只对比训练的时间和效果。xLearn的代码比较简单，同时也支持 csv、libsvm、libffm等多种格式。由于 FFM 算法只支持 libffm格式，实验代码中均用libffm的格式来表示，代码如下：

```
import xlearn as xl #载入工具包
def train_model(model_type = 'ffm', train_path = '', valid_path = ''):
    #训练 lr fm ffm 中其中一个模型
    if model_type == 'ffm':
        model = xl.create_ffm()
    elif model_type == 'fm':
        model = xl.create_fm()
    else:
        model = xl.create_linear()
    print 'This is ',model_type
    model.setTrain(train_path)  #导入训练集
    model.setValidate(valid_path) #导入验证集
    #设定超参数
    param = {'task':'binary', 'lr':0.02, 'lambda':0.002, 'metric':'auc', 'epoch':100, 'k'
    model.fit(param, './model.out') #模型训练
    model.setTest(valid_path) #导入验证集
    model.setSigmoid() #保证输出0-1
    model.predict('./model.out', './output.txt') #预测

if __name__ == "__main__":
    train_path = './data/ffm/tr.ffm' #训练集地址
    valid_path = './data/ffm/va.ffm' #验证集和测试集使用同一个
    #训练3个不同的模型
    train_model('ffm', train_path, valid_path)
    train_model('fm', train_path, valid_path)
    train_model('lr', train_path, valid_path)
```

因为没有封装好的 Python 接口，libfm 和 libffm 不能和 xLearn 一样使用 pip install 等快速安装方式。需要将它们的源码下载到本地利用命令行进行操作， 基本流程是使用 make 命令编译之后生成执行程序，再利用这些程序来训练和预测。保证超参数基本一致，libfm 的训练命令如下：

```
./libFM -task c -train ./data/fm/tr.fm
        -test ./data/fm/va.fm
        -dim '1,1,10' -iter 100
        -method sgd -learn_rate 0.02
        -regular '0,0,0.002'
        -out output
```

其中，c 代表分类任务，参数 dim 表示各维度的操作，前面两个1分别代码加入偏置和一元交叉，10表示二元交叉维度的大小也就是隐变量的维度，参数 regular 分别代表 L0、L1 和 L2

正则的大小。libffm 同样也需要要使用命令行来训练，需要注意的是，与前者不同 libffm 的训练和预测是两个分开的命令。

```
./ffm-train -l 0.002 -k 10 -t 100 -r 0.02
            -p ./data/ffm/va.ffm ./data/ffm/tr.ffm model
./ffm-predict ./data/ffm/va.ffm model output
```

其中，参数 l 表示 L2 正则，r 表示学习率，p 后面的是验证集，这里验证集和测试集使用同一个，model 表示模型文件，output 存放预测结果。tffm 工具包的使用也比较简单，封装好了 sklearn 的接口，与之前工具包不同的是 tffm 的特征并没有使用 lib 类型的存储格式，dense 模式需要转化成矩阵存储，sparse模式使用 scipy 的 csr_matrix 存储。简单的调用代码如下：

```
from tffm import TFFMClassifier
from sklearn import metric
from utils import gen_data #生成样本的本地代码

X_tr, y_tr = gen_data('./data/csv/train.csv')
X_te, y_te = gen_data('./data/csv/valid.csv')

model = TFFMClassifier(
        rank=10,
        optimizer=tf.train.AdamOptimizer(learning_rate=0.002),
        n_epochs=100,
        batch_size=1024,
        init_std=0.001,
        reg=0.02, #正则项
        input_type='dense',
        seed=2019
    )
model.fit(X_tr, y_tr, show_progress=True)
predictions = model.predict(X_te)
print 'AUC: ', metrics.roc_auc_score(y_te, predictions)
model.destroy()
```

实验的结果如下：

算法	AUC	logloss	耗时
LR-xLearn	0.647	0.519	6.42
libfm	0.662	0.483	76.35
libffm	0.664	0.498	137.88
fm-xLearn	0.666	0.485	9.10

算法	AUC	logloss	耗时
ffm-xLearn	0.663	0.492	34.84
tffm	0.658	0.497	220.32

从实验结果可以看出：

（1）xLearn 中实现的算法与 libfm 和 libffm 效果相差不大，性能分别提高了7倍和4倍；

（2）因子分解机模型相比于 LR 有提升；

（3）从该数据集来看，ffm 与 fm 的效果差异不大；

（4）基于 python 和 tensorflow 的 tffm 耗时远大于其他工具包。

根据实验结果，有一些小小的感悟。ffm 对 fm 的提升可能是有限的，模型复杂度却大大增加，真实场景中 ffm 是否能完全替代 fm 有待商榷。tffm 虽然性能不强，效果并没有太多损耗。如今各大公司都是基于深度学习去迭代模型，tffm 不需要太多的开发即可以发布到 tf-serving上，能提高实验的效率。

三、深度FM

3.1 Wide & Deep

机器学习的领域中有一些令人惊艳的算法，它们的出现给研究者们带来了新的思路，甚至开拓了一个流派。在CTR任务中，Google于2016年发表的 Wide and Deep 算法将深度学习应用于 Google Play 的推荐系统中，在行业内引起了不小的轰动。严格意义上来说，W&D 算法和这篇文章主要讲的 FM-based 模型并没有关系，但是它提出来的算法框架值得我们好好研究。目前很多算法，包括后面要提到的 deepFM 和 xDeepFM 都是基于它的算法框架进行改进。

介绍框架之前，先介绍下论文中提到的两个十分关键的名词 memorization 和 generalization。简单的来说，memorization 和 generalization 是处理特征的两种方式，memorization 考虑的是如何将原始特征包含尽可能的表达出来，generalization 则是如何泛化学习到原始特征中隐藏的信息。在查阅资料时，发现一个博文很有意思，文章中有句话很好的解释了 memorization 和 generalization，原文是：The human brain is a sophisticated learning machine, forming rules by memorizing everyday events (“sparrows can fly” and “pigeons can fly”) and generalizing those learnings to

apply to things we haven’ t seen before（“animals with wings can fly”）。通常来说，memorization 可以通过线性模型和特征交叉实现，generalization 则需要更多人工的特征工程。

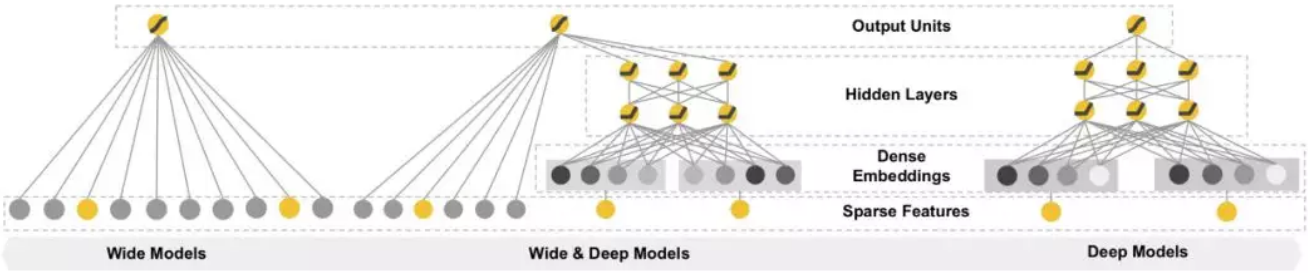

再回到 Wide & Deep 的框架就比较好理解，它可以分为两个部分，左边 Wide 部分为了memorization，右边 Deep 部分为了generalization。算法的思路是 LR + DNN，将 DNN 的输出和左边的 LR 连接，通过 Sigmoid 层得到输出。结合公式更加清楚，

$$P(Y=1|\mathbf{x}) = \sigma\left(\mathbf{w}_{wide}^T[\mathbf{x}, \phi(\mathbf{x})] + \mathbf{w}_{deep}^T a^{(l_f)} + b\right)$$

式中，$\sigma(\cdot)$是 Sigmoid 单元，$\phi(\mathbf{x})$是对原始特征*X*进行的交叉变换，$a^{(l_f)}$表示 Deep部分 通过激活函数的最终输出，***W***和 b 就是常见参数矩阵和偏置。

3.2 DeepFM

计算机行业的飞速发展得益于不断创新和快速迭代。哈工大的一位学长在华为诺亚实现期间提出了DeepFM算法，在 Wide and Deep 的框架基础之上，将因子分解机引入到 Wide 部分。有了之前 Wide and Deep的基础，直接来看 DeepFM 的框架图（论文的图不清楚，重画了一张图）。

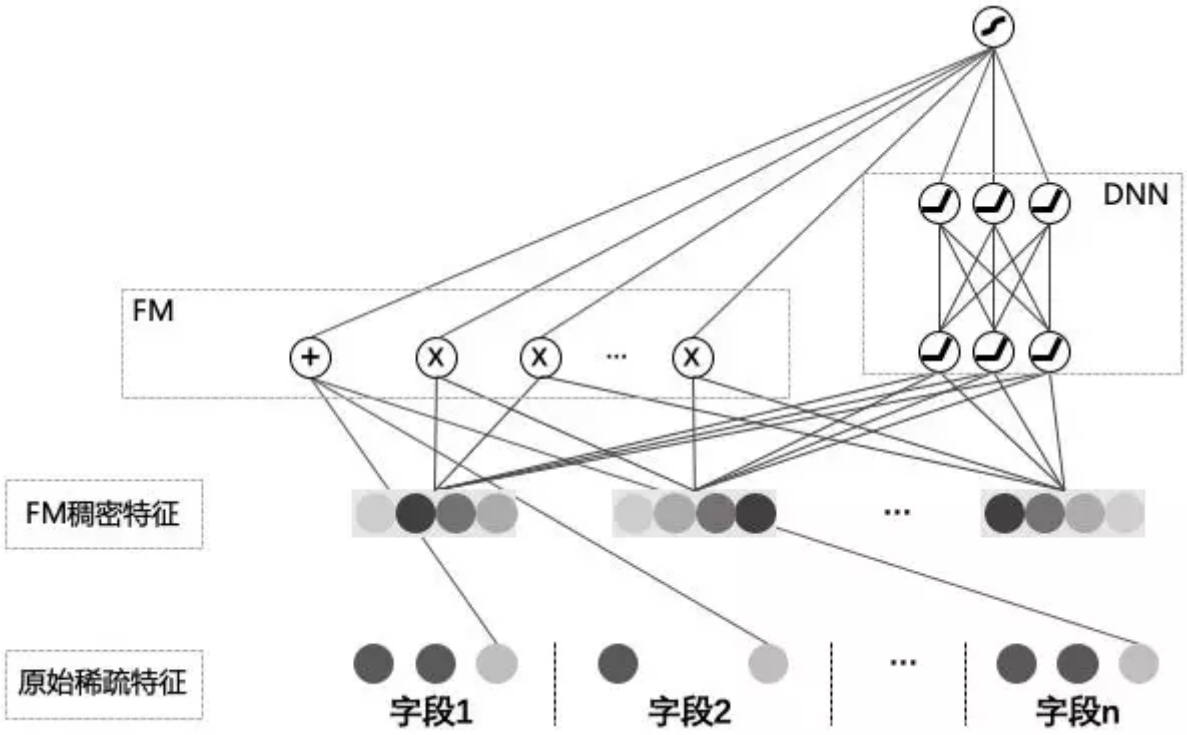

以肉眼可见DeepFM 与 Wide and Deep 最大不同在于，DeepFM 使用了 FM 代替 LR，FM 学习交叉特征而Deep 学习高阶特征。同属于广义线性模型，和 LR 相比 FM 的优势在于可以自动学习特征的交叉，同时又可以处理稀疏的特征，减少了使用 LR 在特征工程上的部分工作量。DeepFM 另一个重要的变化是参数共享，Wide 部分和 Deep 部分都连接在同一个 Embedding 层之后，保证了学习的一致性也提高了模型学习的效率。需要注意的是，FM 层同样用到了原始的稀疏作为输入。论文中还提到，由于DeepFM是端到端的训练，不需要在原始稀疏数据上做任何的人工特征工程。针对这一点，我表示怀疑，算法能学习到的始终是数学表达，脱离真实场景去对数据进行建模并不一定可行，因此针对具体业务逻辑进行人工特征工程是有必要的。

3.3 xDeepFM

在KDD 2018上提出一个新的模型——极深因子分解机（xDeepFM），主要是针对 DeepFM 和 DCN 进行改进。首先，xDeepFM的算法框架仍然沿用 Wide and Deep 的框架，在 Wide 部分加入了作者称之为压缩交互网络（Compressed Interaction Network， 简称 CIN）的神经模型结构。先上整体的框架图。

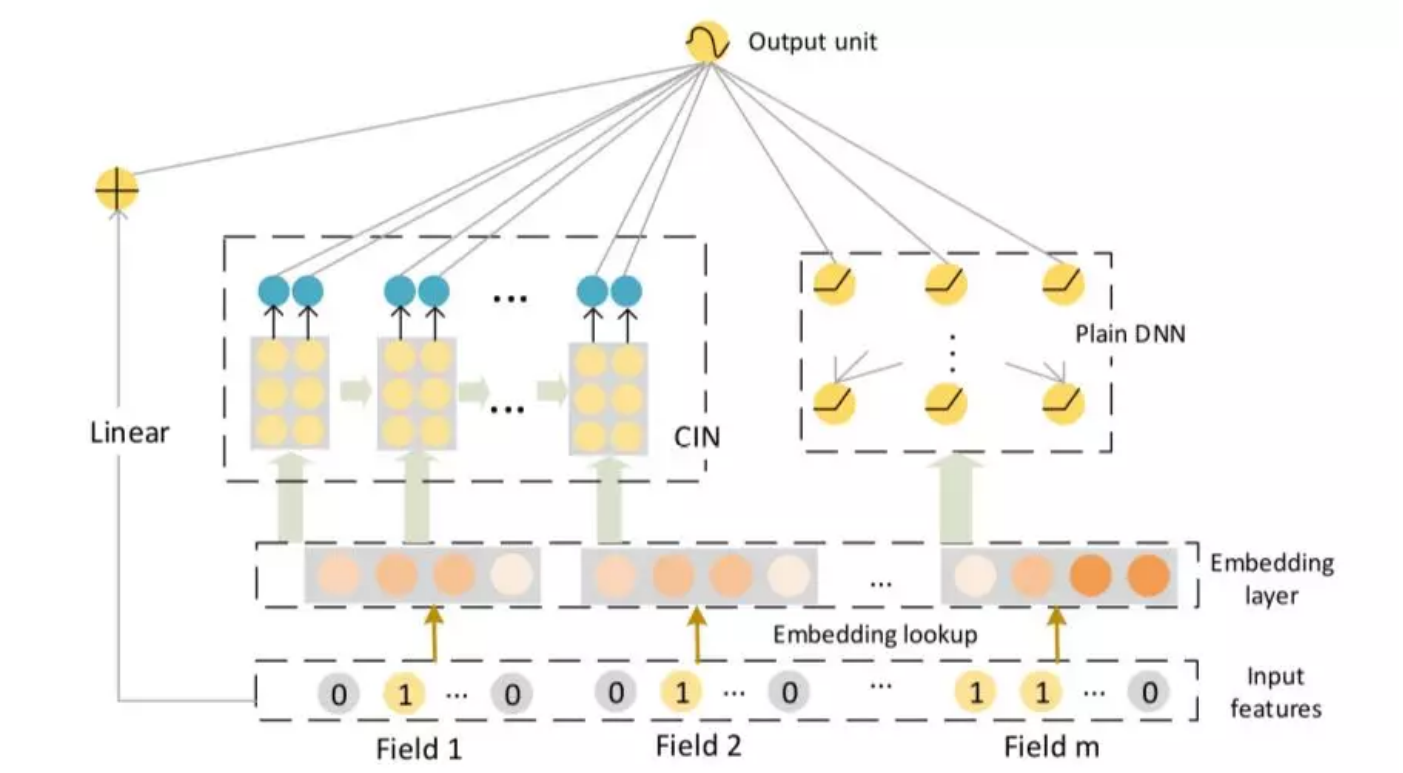

xDeepFM 仍然沿用了 DeepFM 中 Embedding 共享的思路，文中没有列出的 DCN 也是如此。DCN 的改动是将 DeepFM 中的 FM Layer 替换成 Cross Network 为了学习二阶以上的交叉特征，有兴趣的可以看看原论文。受到 DCN 的启发，总结DCN存在的缺点，xDeepFM 的作者提出了更有效的解决办法。先介绍一下，CIN 和 其他模型不同的是特征交叉为显式的向量级（Vector-wise），而不是隐式的元素级（bit-wise）。举个例子，两个特征向量分别为 (a 1, b 1, c 1) 和 (a 2, b 2, c 2)，f 是交叉函数，如果交叉的形式如 f(w 1 * a 1 * a 2, w 2 * b 1 * b 2, w 3 * c 1 * c 2) 为元素级的，若为 f(w*(a 1 * a 2, b 1 * b 2, c 1 * c 2)) 则称之为向量级。该作者认为，向量级的交叉特征更符合因子分解机的初衷，特征交互发生在向量级，更兼具记忆与泛化的学习能力。

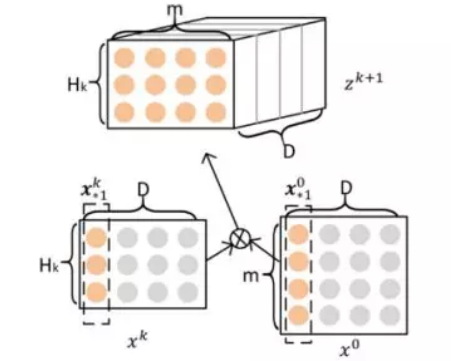

(a) Outer products along each dimension for feature interactions. The tensor Z^{k+1} is an intermediate result for further learning.

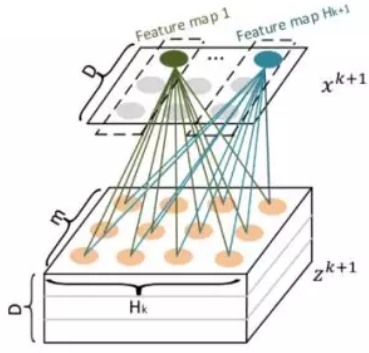

(b) The k-th layer of CIN. It compresses the intermediate tensor Z^{k+1} to H_{k+1} embedding vectors (aslo known as *feature maps*).

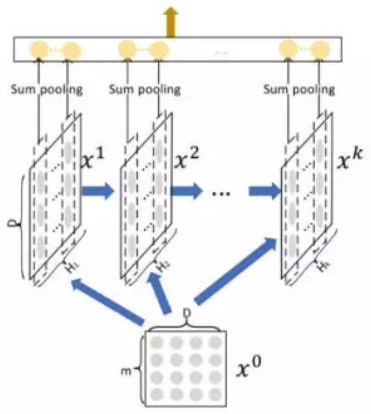

(c) An overview of the CIN architecture.

下面简单介绍下 CIN，在 CIN 中每一层的神经元都是根据前一层的隐层以及原特征向量推算而来，其计算公式如下：

$$\mathbf{X}_{h,-}^{k}=\sum_{i=1}^{H_{k-1}}\sum_{j=1}^{m}\mathbf{W}_{ij}^{k,h}\left(\mathbf{X}_{i,-}^{k-1}\circ\mathbf{X}_{j,-}^{0}\right)$$

CIN 的计算主要有两个步骤：(1) 根据前一层隐层状态$\mathbf{X}_{i,-}^{k-1}$和原始输入数据$\mathbf{X}_{j,-}^{0}$，计算中间结果Z；(2) 根据中间结果，计算下一层隐层的状态。从上面的图可以看出，其实步骤(1)操作类似于RNN网络，而步骤(2)相当于 CNN 中池化的操作，这样看来 CIN 其实是结合了 RNN 和 CNN 的一种网络结构。

第一步实现的是特征维度的相互交叉，通过对原始数据的tensor和隐藏状态点乘操作计算出中间结果。两个2维从图 a 中可以看出，$\mathbf{X}_{i,-}^{k-1}$和$\mathbf{X}_{i,-}^{k-1}$都是一个二维的矩阵，如何利用二维的矩阵相乘得到一个三维矩阵？结合下图代码来说明一下。

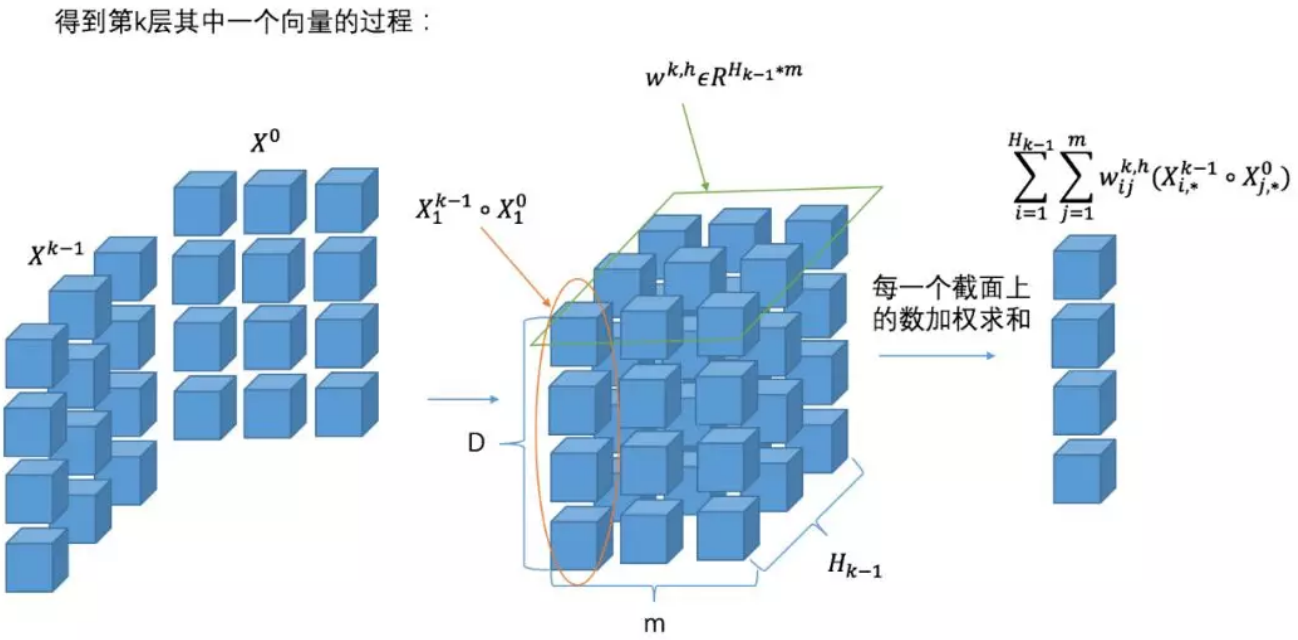


```
for idx, layer_size in enumerate(hparams.cross_layer_sizes):
    """计算每一层的中间状态"""
    #先利用将特征分隔
    split_tensor = tf.split(hidden_nn_layers[-1], hparams.dim * [1], 2)
    #点乘操作
    dot_result_m = tf.matmul(split_tensor0, split_tensor, transpose_b=True)
    #通过reshape和transpose操作变成一个三维向量
    dot_result_o = tf.reshape(dot_result_m, shape=[hparams.dim, -1, field_nums[0]*field_r
    dot_result = tf.transpose(dot_result_o, perm=[1, 0, 2])
```

第二步中类似CNN的结构就比较简单，论文中采用了Sum-poling的池化方式，代码也很简单。

```
filters = tf.get_variable(name="f_"+str(idx),
```

```
                    shape=[1, field_nums[-1]*field_nums[0], layer_size],
                    dtype=tf.float32)
curr_out = tf.nn.conv1d(dot_result, filters=filters, stride=1, padding='VALID')
```

之后将串联在一起组成 CIN 层的输出。

```
curr_out = tf.transpose(curr_out, perm=[0, 2, 1]) #转置
final_result.append(direct_connect) #有直接连接和非直接连接两种
hidden_nn_layers.append(next_hidden)
result = tf.concat(final_result, axis=1)
result = tf.reduce_sum(result, -1)

hparams.logger.info("no residual network")
w_nn_output = tf.get_variable(name='w_nn_output',
                              shape=[final_len, 1],
                              dtype=tf.float32)
b_nn_output = tf.get_variable(name='b_nn_output',
                              shape=[1],
                              dtype=tf.float32,
                              initializer=tf.zeros_initializer())
self.layer_params.append(w_nn_output)
self.layer_params.append(b_nn_output)
exFM_out = tf.nn.xw_plus_b(result, w_nn_output, b_nn_output)
```

除了 CIN 之外，剩下的Linear部分和 DNN 部分，xDeepFM 和 deepFM模型保持一致。CIN 层和 DNN层公用一个 Embedding 结果，然后将三者相加送入 Sigmoid 得到最终结果。

```
with tf.variable_scope("exDeepFm") as scope:
    with tf.variable_scope("embedding", initializer=self.initializer) as escope:
        self.embedding = tf.get_variable(name='embedding_layer',
                                         shape=[hparams.FEATURE_COUNT, hparams.dim],
                                         dtype=tf.float32)
        self.embed_params.append(self.embedding)
        embed_out, embed_layer_size = self._build_embedding(hparams)
    logit = self._build_linear(hparams) #Linear部分
    #加上CIN部分
    logit = tf.add(logit, self._build_extreme_FM(hparams, embed_out, res=False, direct=Fa
    #加上DNN部分
    logit = tf.add(logit, self._build_dnn(hparams, embed_out, embed_layer_size))
    return logit
```

最后奉上之前用到小批量数据中的实验的效果对比。

算法	AUC	logloss
Wide and Deep	0.653	0.508

算法	AUC	logloss
DCN	0.648	0.522
DeepFM	0.661	0.489
xDeepFM	0.669	0.481

可能由于数据量过少等原因，导致深度学习的模型并没有太大的优势，但是通过纵向对比，发现xDeepFM模型相比其他模型在AUC上有明显提升。

参考资料


```
[1]: https://tech.meituan.com/2016/03/03/deep-understanding-of-ffm-principles-and-practic
[2]: https://www.csie.ntu.edu.tw/~r01922136/slides/ffm.pdf
[3]: https://xlearn-doc-cn.readthedocs.io/en/latest/
[4]: https://ke.com
[5]: http://sungsoo.github.io/2017/03/27/wide-and-deep-learning-memorization-generalizati
[6]: https://arxiv.org/pdf/1606.07792.pdf
[7]: https://arxiv.org/pdf/1703.04247.pdf
[8]: https://arxiv.org/pdf/1803.05170.pdf
```


本文作者

> 赵群，2019年1月毕业于哈尔滨工业大学智能计算研究中心，毕业后加入贝壳语言智能与搜索部，主要从事搜索排序优化工作。

文章已于2019-07-02修改